

1. 根据下表 1 所给的训练数据集，利用信息增益比（C4.5 算法）生成决策树。

答：特征(年龄)的信息增益比为 0.052

特征(有工作)的信息增益比为 0.352

特征(有自己的房子)的信息增益比为 0.433

特征(信贷情况)的信息增益比为 0.232

特征(有自己的房子)的信息增益比最大，选择为根节点划分特征

当有自己的房子为是

此时类别均为是，纯净，停止划分

当有自己的房子为否

特征(年龄)的信息增益比为 0.164

特征(有工作)的信息增益比为 1.000

特征(信贷情况)的信息增益比为 0.340

特征(有工作)的信息增益比最大，选择为当前节点特征


当有工作为否

此时类别均为否，纯净，停止划分

当有工作为是

此时类别均为是，纯净，停止划分

决策树如下：



2. 对下表 1 所给的训练数据集，根据信息增益准则选择最优特征。

答：特征(年龄)的信息增益为 0.083

特征(有工作)的信息增益为 0.324

特征(有自己的房子)的信息增益为 0.420

特征(信贷情况)的信息增益为 0.363

特征(有自己的房子)的信息增益最大，选择为根节点划分特征

当有自己的房子为是

此时类别均为是，纯净，停止划分

当有自己的房子为否

特征(年龄)的信息增益为 0.252

特征(有工作)的信息增益为 0.918

特征(信贷情况)的信息增益为 0.474

特征(有工作)的信息增益最大，选择为当前节点特征


当有工作为否

此时类别均为否，纯净，停止划分

当有工作为是

此时类别均为是，纯净，停止划分

决策树如下：



3. 根据下表 1 所给的训练数据集，利用 ID3 算法生成决策树。

答：同 2

4. 根据下表 1 所给的训练数据集，利用 CART 算法生成决策树。

答：特征(年龄)的基尼系数为 0.4267

特征(有工作)的基尼系数为 0.3200

特征(有自己的房子)的基尼系数为 0.2667

特征(信贷情况)的基尼系数为 0.2844

特征(有自己的房子)的基尼系数最小，选择为根节点划分特征

当有自己的房子为否

特征(年龄)的基尼系数为 0.3148

特征(有工作)的基尼系数为 0

特征(信贷情况)的基尼系数为 0.2222

特征(有工作)的基尼系数最小，选择为当前节点特征

其他节点纯净，停止划分（同 1、2）

决策树如下：




表 1 贷款申请样本数据表

ID	年龄	有工作	有自己的房子	信贷情况	类别
1	青年	否	否	一般	否
2	青年	否	否	好	否
3	青年	是	否	好	是
4	青年	是	是	一般	是
5	青年	否	否	一般	否
6	中年	否	否	一般	否
7	中年	否	否	好	否
8	中年	是	是	好	是
9	中年	否	是	非常好	是
10	中年	否	是	非常好	是
11	老年	否	是	非常好	是
12	老年	否	是	好	是
13	老年	是	否	好	是
14	老年	是	否	非常好	是
15	老年	否	否	一般	否

5. 已知如下表所示的训练数据，试用平方误差损失准则生成一个二叉回归树。

x	1	2	3	4	5	6	7	8	9	10
y	4.50	4.75	4.91	5.34	5.80	7.05	7.90	8.23	8.70	9.00

答：

- a. 初始节点：mean = $(4.50 + 4.75 + 4.91 + 5.34 + 5.80 + 7.05 + 7.90 + 8.23 + 8.70 + 9.00) / 10 = 6.618$

总平方损失： $\sum_{i=1}^{10} (y_i - \text{mean})^2 = 27.63$ （总损失较大，开始划分节点）

- b. 寻找分割点：

- 遍历可能的分割点：1.5, 2.5, ..., 9.5。

- 对每个分割点，根据下面公式分别计算左侧和右侧的平均值和平方损失。

---以 x=5.5 为例：

第一组 ($x \leq 5.5$) : {4.50, 4.75, 4.91, 5.34, 5.80}

第二组 ($x > 5.5$) : {7.05, 7.90, 8.23, 8.70, 9.00}

计算每组 y 的平均值，然后计算损失：

第一组平均值 $\bar{y}_1$

第一组总损失 $L_1 = \sum (y_{1i} - \bar{y}_1)^2$

第二组平均值 $\bar{y}_2$

第二组总损失 $L_2 = \sum (y_{2i} - \bar{y}_2)^2$

分割点总损失 $L_{total} = L_1 + L_2$

- 计算得到的每个分割点总损失，选择总损失最小的分割点作为划分节点：

---每个分割点的总损失如下：

x=1.5 的总损失：22.648；x=2.5 的总损失：17.702；x=3.5 的总损失：12.193；x=4.5 的总损失：7.379；**x=5.5 的总损失：3.359**；x=6.5 的总损失：5.074；x=7.5 的总损失：10.052；

$x=8.5$ 的总损失: 15.178; $x=9.5$ 的总损失: 21.328。在这些分割点中, $x=5.5$ 有最小的总损失 (3.359), 因此它是最佳的分割点。在构建决策树时, 第一步将会是以 $x=5.5$ 作为根节点的分割条件。

c. 递归分割:

- 对于 $x \leq 5.5$ 的左侧数据集, 重复步骤 b。
- 对于 $x > 5.5$ 的右侧数据集, 也重复步骤 b

d. 终止条件:

假设我们的停止条件是每个节点至少需要包含两个数据点, 那么当数据不能再分时, 递归停止。(根据具体停止划分情况而定)

6. 试析使用“最小训练误差”作为决策树划分选择准则的缺陷。

答: 使用“最小训练误差”作为决策树划分选择准则, 由于使用的是训练集数据, 可能会将训练特征中的一些异常或者偶然作为模型的一部分, 导致过度拟合的问题。

7. 试将 4.4.2 节对缺失值的处理机制推广到基尼指数的计算中去。

$$\text{Gini-index}(D, a) = \rho * \text{Gini-index}(\bar{D}, a) = \rho * \sum_{v=1}^V \tilde{r}_v \text{Gini}(D^v)$$

$$\text{Gini}(D^v) = 1 - \sum_{k=1}^{|\gamma|} \hat{p}_k^2$$

8. 某公司招聘职员考查身体、业务能力、发展潜力这 3 项。身体分为合格 1、不合格 0 两级, 业务能力和发展潜力分为上 1、中 2、下 3 三级。分类为合格 1、不合格-1 两类。已知 10 个人的数据, 如表所示。假设弱分类器为决策树桩。试用 AdaBoost 算法学习一个强分类器。

应聘人员情况数据表

	1	2	3	4	5	6	7	8	9	10
身体	0	0	1	1	1	0	1	1	1	0
业务能力	1	3	2	1	2	1	1	1	3	2
发展潜力	3	1	2	3	3	2	2	1	1	1
分类	-1	-1	-1	-1	-1	-1	1	1	-1	-1

答: 编程题, 采用 sklearn 的 AdaBoostClassifier 分类器, 构建并训练得到强分类器

([https://scikit-](https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.AdaBoostClassifier.html)

[learn.org/stable/modules/generated/sklearn.ensemble.AdaBoostClassifier.html](https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.AdaBoostClassifier.html))

9. 给定如表所示训练数据。假设弱分类器由 $x < v$ 或 $x > v$ 产生, 其阈值 v 使该分类器在训练数据集上分类误差率最低。试用 AdaBoost 算法学习一个强分类器。

序号	1	2	3	4	5	6	7	8	9	10
x	0	1	2	3	4	5	6	7	8	9
y	1	1	1	-1	-1	-1	1	1	1	-1

答:

计算步骤:

1. 初始化权重: 初始时, 每个样本的权重都是相等的, 即 $w_i = \frac{1}{N}$, 其中 N 是样本数量, 每个样本的初始权重是 0.1。
2. 对于每一轮:
 - 选择阈值 v 最小化加权分类误差。
 - 计算加权误差率 $\epsilon = \sum_{\text{错误}_i} w_i$ 。
 - 计算弱分类器的权重 $\alpha = \frac{1}{2} \ln\left(\frac{1-\epsilon}{\epsilon}\right)$ 。
 - 更新样本权重: 对于正确分类的样本, $w_i \leftarrow w_i \times e^{-\alpha}$, 对于错误分类的样本, $w_i \leftarrow w_i \times e^{\alpha}$ 。然后归一化所有样本权重使它们总和为 1。(这一步 PPT 上没有, 可以实施也可以不实施)
3. 组合弱分类器: 最终的强分类器是所有弱分类器的加权组合, 即 $\text{sign}(\sum_t \alpha_t h_t(x))$, 其中 $h_t(x)$ 是第 t 轮的弱分类器。

以第一轮为例:

在第一轮中, 最佳阈值 v 是 2, 方向是 "greater" (即 $x > 2$), 所有 x 值大于 2 的被分类为 -1, 否则为 1。弱分类器的加权误差率是 0.3。

弱分类器的权重 $\alpha = 0.424$, 然后更新训练样本的权重。这将为下一轮的弱分类器训练提供基础。

前五轮迭代:

$$\begin{aligned}\alpha &\approx 0.424, v = 2, ">" \\ \alpha &\approx 0.650, v = 8, ">" \\ \alpha &\approx 0.752, v = 6, "<" \\ \alpha &\approx 0.711, v = 2, ">" \\ \alpha &\approx 0.726, v = 8, ">"\end{aligned}$$

这些弱分类器组合成一个强分类器, 强分类器的决策基于所有弱分类器的加权投票结果。使用这些弱分类器来对新数据进行分类以检验强分类器的性能。

10. 试析随机森林为何比决策树 Bagging 集成的训练速度更快。

答: 决策树的生成过程中, 最耗时的就是搜寻最优切分属性; 随机森林在决策树训练过程中引入了随机属性选择, 大大减少了此过程的计算量; 因而随机森林比普通决策树 Bagging 训练速度要快。

11. Gradient Boosting [Friedman, 2001] 是一种常用的 Boosting 算法, 试析其与 AdaBoost 的异同。

答: Gradient Boosting 和其它 Boosting 算法一样, 通过将表现一般的数个模型 (通常是深度固定的决策树) 组合在一起来集成一个表现较好的模型。抽象地说, 模型的训练过程是对一任意可导目标函数的优化过程。通过反复地选择一个指向负梯度方向的函数, 该算法可被看做在函数空间里对目标函数进行优化。因此可以说 Gradient Boosting = Gradient Descent + Boosting。和 AdaBoost 一样, Gradient Boosting 也是重复选择一个表现一般的模型并且每次基于先前模型的表现进行调整。不同的是, AdaBoost 是通过提升错分数据点的权重来定位模型的不足而 Gradient Boosting 是通过算梯度 (gradient) 来定位模型的不足。因此相

比 AdaBoost, Gradient Boosting 可以使用更多种类的目标函数。

12. 试析 Bagging 通常为何难以提升朴素贝叶斯分类器的性能。

答：通常情况下，Bagging 难以显著提升朴素贝叶斯分类器的性能，这是因为朴素贝叶斯分类器本身在处理特征之间存在强相关性或者特征空间较大时表现较好，而 Bagging 主要用于降低高方差的模型，对于朴素贝叶斯这种低方差高偏差的模型，Bagging 的效果并不明显。此外，朴素贝叶斯已经假设了特征之间的独立性，而 Bagging 通过随机抽样生成的子模型可能会打破这一假设，从而影响了 Bagging 对朴素贝叶斯的性能提升。

13. 简述如何增强个体学习器的多样性。

答：增强个体学习器的多样性是提高集成学习性能的关键。以下是几种常用的方法：

数据抽样：通过对训练数据进行抽样来生成不同的训练集，个体学习器就可以在不同的数据子集上进行训练。例如，随机森林中的每棵树都是在数据的不同随机子集上训练的。

特征抽样：对于特征丰富的数据集，可以通过随机选择部分特征来训练不同的学习器。这种方法在处理高维数据时特别有效。

使用不同的算法：集成不同类型的学习算法可以增加多样性。例如，可以将决策树、神经网络和支持向量机等不同类型的学习器组合起来。

调整超参数：即使是同一种算法，不同的超参数设置也会导致学习过程的差异，从而产生多样性。

引入随机性：在学习过程中引入随机性，如随机选择初始权重或随机决定网络的结构，也可以产生不同的学习器。

1. 对于图 5.7 中的 v_{ih} ，试推导出 BP 算法中的更新公式 (5.13) 。

$\Delta v_{ih} = -\eta \frac{\partial E_k}{\partial v_{ih}}$ ，因 v_{ih} 只在计算 b_h 时用上，所以 $\frac{\partial E_k}{\partial v_{ih}} = \frac{\partial E_k}{\partial b_h} \frac{\partial b_h}{\partial v_{ih}}$ ，其中 $\frac{\partial b_h}{\partial v_{ih}} = \frac{\partial b_h}{\partial a_h} \frac{\partial a_h}{\partial v_{ih}} = \frac{\partial b_h}{\partial a_h} x_i$ ，所以 $\frac{\partial E_k}{\partial v_{ih}} = \frac{\partial E_k}{\partial b_h} \frac{\partial b_h}{\partial a_h} x_i = -e_h x_i$ ，即得原书中5.13式。

2. 试述式 (5.6) 中学习率的取值对神经网络训练的影响。

学习率太高会导致误差函数来回震荡，无法收敛；而学习率太低则会收敛太慢，影响训练效率。

3. Minsky 与 Papert 指出：单层感知机因为是线性模型，所以不能表示复杂的函数，如异或 (XOR)。验证单层感知机为什么不能表示异或。

假设感知机模型可以表示异或问题，即满足异或函数(XOR)输入与输出的情况（见第1步）。假设 x 向量只有两个维度 x_1, x_2 ：

1. 根据 $x_1 = 0, x_2 = 0, f(x) = -1$ ，则 $w \cdot x + b < 0$ ，可得 $b < 0$ ；
2. 根据 $x_1 = 0, x_2 = 1, f(x) = 1$ ，则 $w_2 + b > 0$ ，结合 $b < 0$ ，可得 $w_2 > -b > 0$ ；
3. 根据 $x_1 = 1, x_2 = 0, f(x) = 1$ ，则 $w_1 + b > 0$ ，结合 $b < 0$ ，可得 $w_1 > -b > 0$ ；
4. 根据 $x_1 = 1, x_2 = 1$ ，并结合 $w_1 + b > 0, w_2 > 0$ ，则 $w_1 + w_2 + b > 0$ ，可得 $f(x) = 1$ ，与异或条件中的 $f(x) = -1$ 矛盾。

所以假设不成立，原命题成立，即感知机模型不能表示异或。

4. 正样本点是 $x_1 = (3, 3)^T, x_2 = (4, 3)^T$ ，负样本点是 $x_3 = (1, 1)^T$ ，试用梯度下降算法求解感知机模型，模型参数初值取 0。

表 2.1 例 2.1 求解的迭代过程


迭代次数	误分类点	w	b	$w \cdot x + b$
0		0	0	0
1	x_1	$(3, 3)^T$	1	$3x^{(1)} + 3x^{(2)} + 1$
2	x_3	$(2, 2)^T$	0	$2x^{(1)} + 2x^{(2)}$
3	x_3	$(1, 1)^T$	-1	$x^{(1)} + x^{(2)} - 1$
4	x_3	$(0, 0)^T$	-2	-2
5	x_1	$(3, 3)^T$	-1	$3x^{(1)} + 3x^{(2)} - 1$
6	x_3	$(2, 2)^T$	-2	$2x^{(1)} + 2x^{(2)} - 2$
7	x_3	$(1, 1)^T$	-3	$x^{(1)} + x^{(2)} - 3$
8	0	$(1, 1)^T$	-3	$x^{(1)} + x^{(2)} - 3$

5. 简述神经网络需要激活函数的原因，并比较 sigmoid、tanh、ReLU 函数分别作为激活函数的效果有何区别。

- Sigmoid 函数：

Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$



形状：


范围：(0, 1)。

特点：平滑且连续，但容易引起梯度消失问题，且输出不是以 0 为中心的。主要用于输出层，在二分类问题中尤为常见。

- Tanh 函数：

tanh

$$\tanh(x)$$



形状：


范围：(-1, 1)。

特点：输出以 0 为中心，可以缓解梯度消失的问题，但在极端值处仍然可能发生。隐藏层中比 sigmoid 更常见。

- ReLU 函数：

ReLU

$$\max(0, x)$$




形状：

范围：[0, ∞)。


特点：计算简单，加速神经网络的收敛，减轻了梯度消失问题。但有可能导致神经元“死亡”（在训练过程中某些神经元可能永远不被激活）。在现代神经网络架构中极为普遍，尤其是在隐藏层中。

6. 根据图示分界线给出与门神经网络的参数 w_1 , w_2 , b 。




1, 1, -1.5

7. 根据图示分界线给出或门神经网络的参数 w_1, w_2, b .



1, 1, -0.5

8. 根据图示分界线给出异或门神经网络的参数 w_i, b_i .



9. 梯度下降算法的正确步骤是什么？

- 计算预测值和真实值之间的误差
- 重复迭代，直至得到网络权重的最佳值
- 把输入传入网络，得到输出值
- 用随机值初始化权重和偏差
- 对每一个产生误差的神经元，调整相应的（权重）值以减小误差

dcaeb

10. 下列哪一项在神经网络中引入了非线性

- 随机梯度下降
- 修正线性单元 (ReLU)
- 卷积函数

b

11. 在感知机中 (Perceptron) 的任务顺序是什么?

- a. 随机初始化感知机的权重
- b. 去到数据集的下一批 (batch)
- c. 如果预测值和输出不一致, 则调整权重
- d. 对一个输入样本, 计算输出值

adcb

12. 下列哪个函数不可以做激活函数?

- a. $y = \tanh(x)$
- b. $y = \sin(x)$
- c. $y = \max(x, 0)$
- d. $y = 2x$

d

13. 下列关于神经元的描述中, 哪一项是正确的?

- a. 每个神经元可以有一个输入和一个输出
- b. 每个神经元可以有多个输入和一个输出
- c. 每个神经元可以有一个输入和多个输出
- d. 每个神经元可以有多个输入和多个输出

d

14. 在一个神经网络中, 知道每一个神经元的权重和偏差是最重要的一步。如果知道了神经元准确的权重和偏差, 便可以近似任何函数, 但怎么获知每个神经的权重和偏移呢?

- a. 搜索每个可能的权重和偏差组合, 直到得到最佳值
- b. 赋予一个初始值, 然后检查跟最佳值的差值, 不断迭代调整权重
- c. 随机赋值


b

15. 如果我们用了一个过大的学习速率会发生什么？

- a. 神经网络会收敛
- b. 不好说
- c. 都不对
- d. 神经网络不会收敛

d

1. 在训练神经网络时，损失函数（Loss）在最初的几个 epochs 时没有下降，可能的原因是？



学习率太低；正则参数太高；陷入局部最小值

2. 批规范化（Batch Normalization）的好处有？

- a. 让每一层的输入的范围都大致固定
- b. 它将权重的归一化平均值和标准差
- c. 它是一种非常有效的反向传播（BP）方法
- d. 这些均不是

a

3. 在一个神经网络中，下面哪种方法可以用来处理过拟合？

- a. Dropout
- b. Batch Normalization
- c. 正则化
- d. 以上都可以


d

4. 考虑某个具体问题，你可能只有少量数据来解决这个问题。不过幸运的是你有一个类似问题已经预先训练好的神经网络。可以用下面哪种方法来利用这个预先训练好的网络？

- a. 把除了最后一层外所有的层都冻结，重新训练最后一层
- b. 对新数据重新训练整个模型
- c. 只对最后几层进行调参（fine tune）
- d. 对每一层模型进行评估，选择其中的少数来使用

c

5. 下图是一个利用 sigmoid 函数作为激活函数的含四个隐藏层的神经网络训练的梯度下降图。这个神经网络遇到了梯度消失的问题。下面哪个叙述是正确的（纵坐标表示梯度大小）？



- 第一隐藏层对应 D，第二隐藏层对应 C，第三隐藏层对应 B，第四隐藏层对应 A
- 第一隐藏层对应 A，第二隐藏层对应 C，第三隐藏层对应 B，第四隐藏层对应 D
- 第一隐藏层对应 A，第二隐藏层对应 B，第三隐藏层对应 C，第四隐藏层对应 D
- 第一隐藏层对应 B，第二隐藏层对应 D，第三隐藏层对应 C，第四隐藏层对应 A


a

6. 对于一个分类任务，如果开始时神经网络的权重不是随机赋值的，而是都设成 0，下面哪个叙述是正确的？

- 其他选项都不对
- 没啥问题，神经网络会正常开始训练
- 神经网络可以训练，但是所有的神经元最后都会变成识别同样的东西
- 神经网络不会开始训练，因为没有梯度改变

c

7. 下图显示，当开始训练时，误差一直很高，这是因为神经网络在往全局最小值前进之前一直被卡在局部最小值里。为了避免这种情况，我们可以采取下面哪种策略？



- 改变学习速率，比如一开始的几个训练周期不断更改学习速率
- 一开始将学习速率减小 10 倍，然后用动量项 (momentum)
- 增加参数数目，这样神经网络就不会卡在局部最优处
- 其他都不对


a

8. 下列的哪种方法可以用来降低深度学习模型的过拟合问题？ 1.增加更多的数据 2.使用数据扩增技术（data augmentation） 3.使用归纳性更好的架构 4.正则化数据 5.降低架构的复杂度

a. 145
b. 123
c. 1345
d. 都可以

d

9. 当训练一个神经网络来作图像识别任务时，通常会绘制一张训练集误差和交叉训练集误差图来进行调试。在图中，最好在哪个时间停止训练？



c

10. 声明 1：可以通过将所有权重初始化为 0 来训练网络
声明 2：可以通过将偏差初始化为 0 来很好地训练网络。
以上哪些陈述是真实的？

a. 1
b. 2
c. 12
d. 都是错的

b

11. 如果我们希望预测 n 个类 ($p_1, p_2, \dots, p_k$) 的概率使得所有 n 个 p 的和等于 1，那么下列哪个函数可以用作输出层中的激活函数？

a. Softmax
b. Relu
c. Sigmoid
d. Tanh


a

12. 使用批量归一化可以解决神经网络训练中的哪些问题？

- a. 过拟合
- b. 限制输出过大或过小
- c. 训练过慢
- d. 以上所有

d

13. 上面的红色曲线表示关于深度学习算法中每个时期的训练精度。绿色和蓝色曲线都表示验证的准确性。 哪条曲线表示过拟合 overfitting？



- a. 绿色曲线
- b. 蓝色曲线

b

14. 我们可以采取哪些措施来防止神经网络中的过拟合？

- a. 数据增强
- b. 权重共享
- c. 提前停止
- d. Dropout
- e. 以上全部

e

15. 以下模型中，在数据预处理时，不需要考虑归一化处理的是

- a. logistic 回归
- b. SVM
- c. 树形模型
- d. 神经网络

c

16. 假设用 $x \in B$ 表示一个来自小批量 B 的输入, 批量归一化 BN 层的参数为: 拉伸参数 (scale) γ 和偏移参数 (shift) β , 它们的形状与 x 相同。请写出经过批量归一化转换后的 x 表达式 $\text{BN}(x)$ 。

$$\text{BN}(x) = \frac{x - \mathbb{E}(x)}{\sqrt{\text{var}^2(x) + \epsilon}} \odot \gamma + \beta$$

17. 批归一化和 Dropout 一般不会同时使用, 请简述原因。

目标冲突: 批归一化的目的是调整激活层的输出, 使其保持一定的均值和方差, 从而加速训练过程并提高模型稳定性。Dropout 则是通过随机地关闭神经网络中的一部分神经元, 来防止模型对特定的训练数据过拟合。这两种技术的目标不同。批归一化希望保持激活值的分布稳定, 而 Dropout 则通过引入噪声来增加网络的泛化能力, 这在一定程度上是相互矛盾的。

内部协变量偏移: 批归一化通过规范化激活层的输出来减少内部协变量偏移。但是, 当使用 Dropout 时, 由于随机关闭神经元, 激活层的输出分布在每次迭代中都会发生变化, 这可能会破坏批归一化试图解决的问题。

训练动态: 当同时使用这两种技术时, 网络的训练动态可能会受到干扰。Dropout 会改变网络中信息的流动方式, 而批归一化依赖于这些信息的稳定分布来进行有效的规范化。这种干扰可能会导致训练过程不稳定, 甚至降低模型性能。

18. 简述 Dropout 能够防止过拟合的原因。

模拟集成学习: Dropout 通过在训练过程中随机关闭 (即设为零) 网络中的一部分神经元, 可以被看作是在训练每个小批量数据时都使用了一个略有不同的网络结构。这类似于训练多个不同的模型并进行集成学习。在测试时, 使用所有神经元 (通常会调整其输出以反映训练时的 Dropout 比例) 相当于对这些“模型”进行平均, 这有助于减少模型对特定训练样本的过度依赖, 提高其泛化能力。

减少复杂共适应性: 在没有 Dropout 的情况下, 网络的神经元可能会学会共同适应并对特定的训练数据过度拟合, 即它们共同调整它们的行为来记住训练数据的特定特征。使用 Dropout 意味着网络的神经元不能依赖于特定其他神经元的存在, 因为这些神经元可能在任何给定的训练步骤中被“丢弃”掉。因此, 每个神经元必须学习更加鲁棒的特征, 这些特征在各种不同的网络子集中都有用。

减少过度依赖: 在传统的神经网络中, 某些神经元可能对特定的特征或模式过度敏感, 导致过拟合。Dropout 强迫网络在缺少部分信息的情况下进行学习, 这减少了模型对任何单个神经元的依赖, 从而减少了过拟合的风险。

正则化效果: 从正则化的角度来看, Dropout 可以被视为一种增加模型的随机性、降低模型复杂度的方式。通过在训练期间引入噪声, Dropout 防止了网络对训练数据的“记忆效应”, 从而起到了类似于传统正则化技术 (如 L1 或 L2 正则化) 的作用。

19. 假设 Dropout 概率为 p , 为了保证期望值不变, 则在测试时, 该层模型权重 w 应该变为? $1 - p$

20. 设模型初始参数 θ_0 为 $[0.1, 0.2]$, 学习率为 0.1, 动量更新权重为 1, 若模型在两次训练过程中的梯度依次为 $g_0 = [2, -1]$, $g_1 = [1, -2]$, 求两次训练后模型的参数 θ_2 . $[-0.4, 0.6]$

ML_卷积神经网络

填空题

- 1, 假设输入的图像的尺寸是 4×4 , 卷积核的尺寸是 3×3 , 步幅是1; 如果将填充设置为 1×1 , 则输出数据的尺寸是____; 如果将填充设置为 2×2 , 则输出数据的尺寸是____; 如果将填充设置为 3×3 , 则输出数据的尺寸是____;
- 2, 填充 (padding) 在卷积操作中的作用是_____。
- 3, 卷积神经网络反向传播的过程中, 卷积操作的梯度计算通常使用_____算法。
- 4, 在反向传播中, 激活函数的导数被用来计算_____。
- 5, 反向传播中的损失函数对于输出层的梯度计算通常使用_____。
- 6, Batch Normalization 中反向传播的过程涉及到计算对于输入的梯度, 该梯度计算通常需要计算均值和方差的_____。
- 7, 在反向传播中, 全连接层的权重梯度计算通常利用_____算法。
- 8, 反向传播中的优化算法, 如随机梯度下降 (SGD) 的更新规则是通过将参数沿着梯度的_____方向进行更新。

选择题

- 1, 卷积神经网络中的卷积层和池化层分别用于什么目的?
A. 特征提取和降采样
B. 特征降维和特征映射
C. 激活函数和正则化
D. 参数初始化和反向传播
- 2, 在卷积神经网络中, 填充的作用是什么?
A. 增加输出特征图的尺寸
B. 防止卷积操作导致边缘信息丢失
C. 减少模型的参数数量
D. 提高模型的训练速度
- 3, 在卷积神经网络的反向传播中, 梯度下降的目标是调整什么参数?
A. 输入数据
B. 权重和偏置
C. 激活函数的阈值

D. 卷积核的尺寸

4, 反向传播中的池化层的梯度是如何传播的?

A. 池化层没有梯度

B. 反向传播时取池化层输入的最大值作为梯度

C. 反向传播时将梯度均匀分配给池化层输入的所有元素

D. 池化层梯度由卷积层的梯度传播而来

5, 反向传播中的卷积操作涉及哪些参数的梯度更新?

A. 输入数据

B. 卷积核的权重

C. 池化层的输出

D. 批量归一化的参数

判断题

1, 步幅越大, 池化层输出的特征图尺寸越小。

A. 对

B. 错

2, 在卷积神经网络中, 通道数指的是卷积核的数量。

A. 对

B. 错

简答题

1, 卷积神经网络的经典结构有哪些? 简单介绍一下近年来具有代表性的深度卷积神经网络的设计思路;

答案

填空题

1. 4×4 ; 8×8 ; 10×10

2. 防止输入边缘信息丢失。

3. 链式法则 (**chain rule**)

4. 神经元的局部梯度

5. 交叉熵 (**cross-entropy**)

6. 梯度
7. 链式法则 (chain rule)
8. 负方向

选择题

1. A. 特征提取和降采样
2. B. 防止卷积操作导致边缘信息丢失
3. B. 权重和偏置
4. D. 池化层梯度由卷积层的梯度传播而来
5. B. 卷积核的权重

判断题

1. A. 对
 - 在池化层中，步幅 (stride) 表示每次移动的步长，步幅越大，每次移动的距离就越远，导致输出特征图的尺寸减小。这是因为池化操作会在输入特征图上以一定的步幅滑动，然后在每个滑动窗口上执行池化操作，取窗口内的最大值或平均值。如果步幅较大，每次取样的窗口之间会有重叠，导致输出特征图的尺寸减小。因此，步幅越大，池化层输出的特征图尺寸越小，这有助于减少计算量和参数数量，同时保留主要的特征信息。
2. B. 错
 - 通道数指的是输入和输出的特征图的数量，不是卷积核的数量。

简答题

(参考) 答案参考PPT

卷积神经网络的经典结构有：LeNet, AlexNet, VGG, ResNet;

LeNet:

在80年代末期在银行和邮局等识别手写数字处于支配的地位，名字来源于论文作者Y. LeCun ;LeNet展示了通过梯度下降训练卷积神经网络可以达到手写数字识别在当时最好的结果，是卷积神经网络奠基性的工作，CNN的三个特性:1.局部感知、2.下采样、3.权值共享

AlexNet

2012年被提出，模型名字来源于论文第一作者Alex Krizhevsky，赢得了2012 ImageNet比赛 (Top 5 误差率 15.3%，当年第二好的模型误差率为 26.2%)。AlexNet使用了8层卷积神经网络；其特点有：

AlexNet将Sigmoid激活函数改成了更加简单的ReLU激活函数。

AlexNet通过Dropout(丢弃法)来控制全连接层的模型复杂度。

AlexNet引入了大量的图像增广的方法，如翻转、裁剪和颜色变化，进一步扩大数据集防止过拟合。

不需要进行图像预处理

VGG

VGG组成规律: 连续使用数个相同的填充为1、窗口形状为3x3的卷积层后接上一个步幅为2、窗口形状为2x2的最大池化层。卷积层保持输入的高和宽不变, 而池化层则对其减半。

VGG的名字来源于作者所在的**V**isual **G**eometry **G**roup实验室。该网络是在ILSVRC 2014上的相关工作, 主要工作是证明了增加网络的深度能够在一定程度上影响网络最终的性能。VGG有两种结构, 分别是VGG16和VGG19, 两者并没有本质上的区别, 只是网络深度不一样。提出了可以通过重复使用简单的基础块来构建深度模型的思路。

原理:在VGG中使用3个3x3卷积核代替7x7(ZFNet) 卷积核, 使用2个3x3卷积核来代替5x5(LeNet)卷积核, 在保证具有相同感知野的条件下, 提升了网络的深度, 减小了网络参数, 在一定程度上提升了神经网络的效果。

ResNet

2015年, 何凯明等人提出的残差网络(ResNet)在ImageNet图像识别大赛 夺冠, 并深刻影响了后来的深度学习网络的设计。ResNets解决深度神经网络的“退化”问题。

使用了残差链接:

- 设输入为 x , 如果期望的潜在映射为 $H(x)$, 可以拟合的函数为 $F(x)$ 。与其让 $F(x)$ 直接学习潜在的映射, 不如去学习残差 $H(x)-x$, 即 $F(x):=H(x)-x$, 这样原本的前向路径上就变成了 $F(x)+x$, 用 $F(x)+x$ 来拟合 $H(x)$ 。
- 残差映射在实际中更容易优化。
- 残差块中的输入可以通过跨层的数据线(短路链接, Shortcut)更快的向前传播。

ResNet采用残差块和Shortcut identity mapping, 取得了极其好的效果。

ML_循环神经网络

填空题

1. RNN的基本结构包括三个主要组件，其中_____接收输入序列，_____负责记忆和传递信息，_____产生最终输出。
2. _____可能导致数值溢出，_____可能导致长时依赖问题。应对策略可能包括梯度截断、使用LSTM或GRU等。
3. 在LSTM中，_____用于控制是否遗忘之前的记忆细胞的信息。
4. RNN的“隐藏状态”在网络中的_____层。
5. 描述LSTM中的三个门包括遗忘门、输入门和输出门。_____决定遗忘多少之前的记忆，_____决定存储多少新的信息，_____决定记忆细胞的哪部分被输出。

选择题

1. 为什么在某些任务中选择使用循环神经网络（RNN）而不是其他神经网络结构？（选择题）
 - A. 处理序列数据
 - B. 具有记忆能力
 - C. 适用于时序关系建模
 - D. 所有选项都正确
2. LSTM和GRU是RNN的两种常见变体，它们的主要区别是什么？（选择题）
 - A. LSTM有三个门，而GRU只有两个门
 - B. LSTM具有记忆细胞和输入门
 - C. GRU相对于LSTM参数更少
 - D. 所有选项都正确
3. 在训练中，如果梯度爆炸发生，可能会导致什么问题？（选择题）
 - A. 数值溢出
 - B. 模型参数不稳定
 - C. 训练无法收敛
 - D. 所有选项都正确
4. 对于长序列的处理，LSTM和GRU相对于传统RNN具有哪些优势？（选择题）
 - A. 更好地捕捉长时依赖关系
 - B. 减缓梯度消失问题
 - C. 更适用于时间序列建模
 - D. 所有选项都正确

判断题

1. RNN中的“沿时间反向传播”用于解决梯度传播中的长时依赖问题。

2. 在RNN训练中，正向传播用于计算模型的预测输出，反向传播用于计算梯度以更新模型参数。

简答题

1. 当训练长序列时，梯度爆炸和梯度消失问题可能变得更加显著。请简要解释为什么会出现这些问题。
2. 在选择LSTM或GRU时，你会在什么情况下更倾向于选择其中之一？

答案

填空题

1. 输入层；隐藏层；输出层；
2. 梯度爆炸；梯度消失；
3. 遗忘门
4. 隐藏
5. 遗忘门；输入门；输出门

选择题

1. D. 所有选项都正确
2. D. 所有选项都正确
3. D. 所有选项都正确
4. D. 所有选项都正确

判断题

1. 对
2. 对

简答题

1. 答案：在长序列中，梯度在反向传播时可能多次相乘，导致指数级增长或减小，从而引发梯度爆炸或梯度消失。
2. 答案：倾向选择LSTM当需要更复杂的建模能力时，倾向选择GRU当计算成本和参数数量更为重要时。

ML_生成对抗网络

填空题

1. 生成对抗网络通过_____来实现生成器和判别器的对抗学习。
2. 目标函数的构造过程中，生成器的目标是最小化生成样本与_____之间的差异。
3. 在生成对抗网络的训练过程中，生成器通过_____来调整生成的样本。

选择题

1. 生成对抗网络的目标函数包括以下哪个部分？
 - a. 生成器误差
 - b. 判别器误差
 - c. 生成器和判别器误差
 - d. 目标函数不包括误差
2. 目标函数的全局最优解表示什么情况？
 - a. 生成器和判别器都失效
 - b. 生成器和判别器都取得最佳效果
 - c. 生成器失效，判别器最优
 - d. 判别器失效，生成器最优
3. 在生成对抗网络的训练中，判别器的任务是：
 - a. 最大化生成样本的相似度
 - b. 最小化生成样本的相似度
 - c. 区分真实样本和生成样本
 - d. 不参与训练
4. 生成对抗网络的训练过程中，生成器的优化目标是：
 - a. 最大化生成样本的相似度
 - b. 最小化生成样本的相似度
 - c. 欺骗判别器，使其无法区分真实样本和生成样本
 - d. 保持生成样本的多样性
5. 生成对抗网络的训练中，为什么需要协调生成器和判别器的训练？
 - a. 使生成器过拟合
 - b. 保持判别器过拟合
 - c. 实现平衡，避免其中一个过于强大

- d. 判别器不需要训练
- 6. 在生成对抗网络中，使用哪种损失函数来衡量生成器生成样本的质量？
 - a. 交叉熵损失
 - b. 均方误差损失
 - c. 对抗损失
 - d. KL 散度损失

判断题

- 1. 生成对抗网络的训练过程中，生成器的目标是最大化生成样本与真实样本的相似度。
- 2. 传统生成对抗网络的一个问题是训练不稳定，容易发生模式崩溃现象。
- 3. 生成对抗网络的训练过程是一个零和博弈，生成器和判别器的优化目标是相互矛盾的。
- 4. 生成对抗网络的训练过程中，判别器的目标是最小化生成样本与真实样本的差异。

简答题

- 1. 对传统生成对抗网络有哪些改进方法？

答案

填空题

- 1. 对抗学习
- 2. 真实样本
- 3. 梯度下降

选择题

- 1. c. 生成器和判别器误差
- 2. b. 生成器和判别器都取得最佳效果
- 3. c. 区分真实样本和生成样本
- 4. c. 欺骗判别器，使其无法区分真实样本和生成样本
- 5. c. 实现平衡，避免其中一个过于强大
- 6. c. 对抗损失

判断题

1. 错
2. 对
3. 对
4. 错

简答题

(参考) (请大家参考PPT)

传统的GAN存在的问题：梯度消失，JS散度的问题

解决方法：

1. 不把判别器训练的太好。
2. 给生成数据和真实数据加噪声，强行让生成数据与真实数据在高维空间产生重叠，JS散度就可以发挥作用；

传统GAN存在的问题: 模式崩溃(mode collapse)

解决方法：

1. 从目标函数考虑:当GAN出现模式崩溃问题时，通常判别器在训练样本附近更新 参数时，其梯度值非常大。可对判别器在训练样本附近施加梯度惩罚项。试图在训练 样本附近构建线性函数，因为线性函数为凸函数具有全局最优解。(DRAGAN)
2. 从网络架构考虑:即使单个生成器会产生模式崩溃的问题，但是如果同时构造多 个生成器，且让每个生成器产生不同的模式，则这样的多生成器结合起来也可以保证 产生的样本具有多样性。(MAD (Multi-agent diverse)-GAN)

Wasserstein GAN (WGAN)的提出就是为了解决传统GAN遇到的梯度消失、训练时梯度不稳定以及模式崩溃等问题。

WGAN-GP (GP: gradient penalty) 的提出就是为了解决WGAN遇到的 问题，不再使用WGAN中Weight clipping的方式来粗暴地限制参数范围。

ML_强化学习

填空题

- 1, 最优动作价值函数 Q_* 依赖于_____。
- 2, DQN是对_____的近似。
- 3, 驾车按照“甲, 乙, 丙”行驶, 从甲地出发, 模型预计需要行驶20小时, 实际行驶6小时到达乙地, 模型预计还需12个小时到达丙地, 如果我们用TD算法更新模型, 那么TD目标 $\hat{y} =$ _____小时, TD绝对误差值 $|\delta|$ _____小时;

选择题

- 1, 设 $A = \{\text{上, 下, 左, 右}\}$ 为动作空间, s_t 为当前状态, π 为策略函数, 策略函数的输出:

$$\begin{aligned}\pi(\text{上}|s_t) &= 0.2, \\ \pi(\text{下}|s_t) &= 0.05, \\ \pi(\text{左}|s_t) &= 0.7, \\ \pi(\text{右}|s_t) &= 0.15.\end{aligned}\tag{1}$$

请问, 哪个动作会成为 a_t ?

- A, 下
 - B, 左
 - C, 4种动作都有可能
- 2, 设随机变量 U_t 为 t 时刻的回报, 请问 U_t 依赖于哪些变量?
- A, t 时刻的状态 S_t
 - B, t 时刻的动作 A_t
 - C, S_t 和 A_t
 - D, $S_t, S_{t+1}, S_{t+2}, \dots$ 和 $A_t, A_{t+1}, A_{t+2}, \dots$

- 3, 动作价值函数是什么的期望?

- A, 奖励
- B, 回报
- C, 状态
- D, 动作

- 4, 设 $A = \{\text{上, 下, 左, 右}\}$ 为动作空间, s_t 为当前状态, Q_* 为最优动作价值函数, 策略函数的输出:

$$\begin{aligned} Q_*(s_t, \text{上}) &= 930, \\ Q_*(s_t, \text{下}) &= -60, \\ Q_*(s_t, \text{左}) &= 120, \\ Q_*(s_t, \text{右}) &= 321. \end{aligned} \tag{2}$$

请问，哪个动作会成为 a_t ？

- A, 上
- B, 下
- C, 4种动作都有可能

5, DQN的输出层用于什么激活函数？

- A, 不需要激活函数，因为Q值可正可负，没有取值范围
- B, 用sigmoid激活函数，因为Q值介于0和1之间
- C, 用ReLU激活函数，因为Q值非负
- D, 用softmax激活函数，因为DQN的输出是一个概率分布

6, 多臂赌博机是单步强化学习的经典范例， ϵ 贪心算法和softmax算法用于处理什么问题？

- A, 探索-利用问题
- B, 奖励函数优化问题
- C, 动作选择问题
- D, 状态空间问题

7, DQN（深度 Q 网络）是基于什么的强化学习方法？

- A, 基于值的方法
- B, 基于策略的方法
- C, 基于模型的方法
- D, 基于探索的方法

8, TD gradient 是与哪种强化学习方法相关的概念？

- A, 基于值的方法
- B, 基于策略的方法
- C, 基于模型的方法
- D, 基于探索的方法

9, 在强化学习中，基于策略的方法主要关注什么？

- A, 最大化奖励

- B, 最小化损失
- C, 直接学习值函数
- D, 直接学习策略函数

答案

填空题

1. 最优策略
2. **Q-learning**
3. **18**小时；**2**小时；

选择题

1. C, 4种动作都有可能。
2. D；
3. B；
4. A；
5. A；
6. B；
7. A；
8. A；
9. D；

半监督学习

1. 什么是半监督学习？请简要描述其定义和主要思想。它与监督学习和无监督学习有什么区别？

半监督的学习：有少量训练样本，学习机以从训练样本获得的知识为基础，结合测试样本的分布情况逐步修正已有知识，并判断测试样本的类别。

有监督的学习：学习器通过对大量有标记的训练例进行学习，从而建立模型用于预测未见示例的标记，很难获得大量的标记样本。

无监督的学习：无训练样本，仅根据测试样本的在特征空间分布情况进行标记，准确性差。

2. 解释图半监督学习（graph-based semi-supervised learning）的基本思想和过程。

基于相似的样本具有相同标签的平滑假设，构建图结构，利用节点标签扩散，将已标记样本根据样本特征的相似性进行扩散，获得未标记样本的标记。过程包括：图表示、初始化标签、标签传播、学习模型、分类预测。

3. 什么是半监督聚类？它与传统聚类方法有何不同？

半监督聚类在拥有部分额外监督信息时，可利用监督信息改善聚类效果，结合了有标签的数据和未标签的数据。传统聚类方法通常只使用无标签数据进行聚类。

4. 什么是“伪标签”？它在半监督学习中的作用是什么？

"伪标签"是一种半监督学习中的策略，它通过使用已训练模型对未标记数据进行预测，并将这些预测结果作为虚拟的标签（伪标签）来扩充训练数据。可以扩充训练数据和引入额外信息，但是需要注意误差传播的问题。

迁移学习

1. 什么是迁移学习？请简要描述其定义和主要思想。

迁移学习指利用数据、任务、或模型之间的相似性，将在旧领域学习过的模型，应用于新领域的一种学习过程。迁移学习提供了一种基于大数据“预训练”的模型在自己的特定数据集上进行“微调”的技术。核心思路是找到源域和目标域之间的差异性，并将整体工作归结为两方面：一是度量两个领域的相似性，不仅定性地告诉我们它们是否相似，更定量地给出相似程度；二是以度量为准则，通过我们所要采用的学习手段，增大两个领域之间的相似性，完成迁移学习。

2. 请解释“领域”在迁移学习中的概念。

领域是机器学习的主体，主要由两个部分构成：数据和生成这些数据的概率分布。通常用 D 表示一个领域，可被表示为 $D = \{X, Y, P(x, y)\}$ 。其中 X, Y 分别为数据所处的特征空间和标签空间， P 为数据服从的概率分布。

3. 什么是领域自适应？请简要描述其基本原理。

领域自适应是迁移学习中的一个重要概念，它旨在解决在源领域上训练的模型在目标领域上性能下降的问题。在领域自适应中，源领域和目标领域通常具有不同的分布或特性，例如，它们可能来自不同的传感器、环境或任务设置。

基本原理包括：

- 1) 源领域训练：在源领域上，我们使用标记数据来训练一个模型。这个模型在源领域上表现良好，因为它是在这个领域上训练的。
- 2) 领域间差异：源领域和目标领域之间存在领域间的差异，这些差异可能包括数据分布的不同、特征的变化等。由于这些差异，直接将源领域上训练的模型应用到目标领域上可能导致性能下降。
- 3) 域适应方法：领域自适应的目标是通过调整模型，使其适应目标领域的特点，从而提高在目标领域上的性能。有许多领域自适应方法，其中一些常见的包括：

① 特征层面的适应：调整模型的特征提取层，以减小源领域和目标领域之间的特征差异。

② 实例重权：调整训练样本的权重，使目标领域中的样本在训练中更加重要。

③ 对抗训练：引入对抗性训练，通过最小化源领域和目标领域之间的领域差异来提高泛化性能。

④ 联合训练：在源领域和目标领域上联合训练，以共同优化模型，使其能够适应目标领域。

4) 评估：在目标领域上评估调整后的模型性能，根据评估结果进一步调整和改进领域自适应方法。

4. 什么是源领域和目标领域？什么是领域间距离，如何度量？

源领域：源领域是模型在训练阶段接触到的领域。在源领域中，模型接收到标记数据，通过学习这些数据来训练模型。源领域通常具有相对丰富的标记数据。

目标领域：目标领域是模型在测试或应用阶段面对的领域。在目标领域中，模型通常面临的是没有或很少有标记的数据。迁移学习的目标是通过从源领域学到的知识来提高模型在目标领域上的性能。

将源域和目标域的差异性视为两个域内样本数据的概率分布的差异性进行研究，根据采用显式或隐式的距离度量分为两类：

① 显式度量：由预定义好的距离公式产生的度量，具有特定形式，常用的距离度量有欧式距离、闵可夫斯基距离、马氏隐式度量：并非预先定义好的，而是可以在数据中动态学习的、更适合数据分布的度量距离、余弦相似度等

5. 迁移学习的基本类型有哪些，请简要介绍，并分别列举典型算法

1) 基于样本的迁移学习：根据源领域和目标领域的相似度来学习源领域样本的权重

2) 基于特征的迁移学习：学习一个特征变换 T 来减小迁移正则化项 $R(\cdot, \cdot)$

3) 基于模型的迁移学习：学习如何将源领域的判别函数 $f(\cdot, \cdot)$ 对目标领域数据进行正则化和微调

小样本学习

1. 什么是相似度函数，相似度函数学习的基本思想是什么？

相似度函数 (Similarity Function) 是用于度量两个对象之间相似程度的函数。在机器学习和数据挖掘中，相似度函数通常用于比较两个样本、文档、图像或其他数据表示的对象之间的相似性。相似度函数的设计直接影响了模型的性能，因为它定义了模型对相似性的理解。在迁移学习中，相似度函数可以用于度量源领域和目标领域之间的相似性，或者在特定任务中度量不同任务之间的相似性。

基本思想是从大规模训练数据集中学习一个相似度函数（元学习），将相似度函数用于预测，通过比对查询样本与支持集每一个样本的相似度，找到得分最高的那个。

2. 请介绍相似度函数学习的流程，并解释孪生网络和三元组损失

- 1) 在大规模数据集上训练一个孪生网络
- 2) 给定一个 **k-way, n-shot** 的支持集
- 3) 给定查询样本，预测其属于的分类

孪生网络是一种特殊的神经网络结构，有两个相同的子网络，它们共享相同的权重。这两个子网络分别处理输入样本，然后通过一个比较层（如欧氏距离或余弦相似度）将两个子网络的输出进行比较。孪生网络的训练目标是使得相似的样本在比较层中的距离较小，而不相似的样本的距离较大。对比损失是孪生网络中常用的损失函数。

三元组损失是一种用于训练相似度学习模型的损失函数，通常与三元组网络一起使用。在一个三元组中，包含一个锚点样本和两个样本，一个是正样本，另一个是负样本。三元组损失的目标是通过拉近锚点样本和正样本之间的距离，并推远锚点样本和负样本之间的距离，从而学到一个能够准确衡量相似性的模型。