




机器学习

Machine Learning

授课老师：程骋

电 话：18872285886

邮 箱：c_cheng@hust.edu.cn

第十章、半监督学习

01 半监督学习问题

02 方法概述

生成式方法

Self-Training

半监督SVM

图半监督学习

基于分歧的方法

半监督聚类

03 领域前沿

目录 CONTENTS

为人师表

➤ 为什么用半监督学习?



- 收集数据很容易，但收集“有标签的”数据却不容易
- 我们在生活中经常用到半监督学习

1. 半监督学习问题

□ **问题的提出：**在有标签样本较少时，如何利用无标签样本提升学习性能

有监督的学习：学习器通过对大量有标记的训练例进行学习，从而建立模型用于预测未见示例的标记(label)。很难获得大量的标记样本。

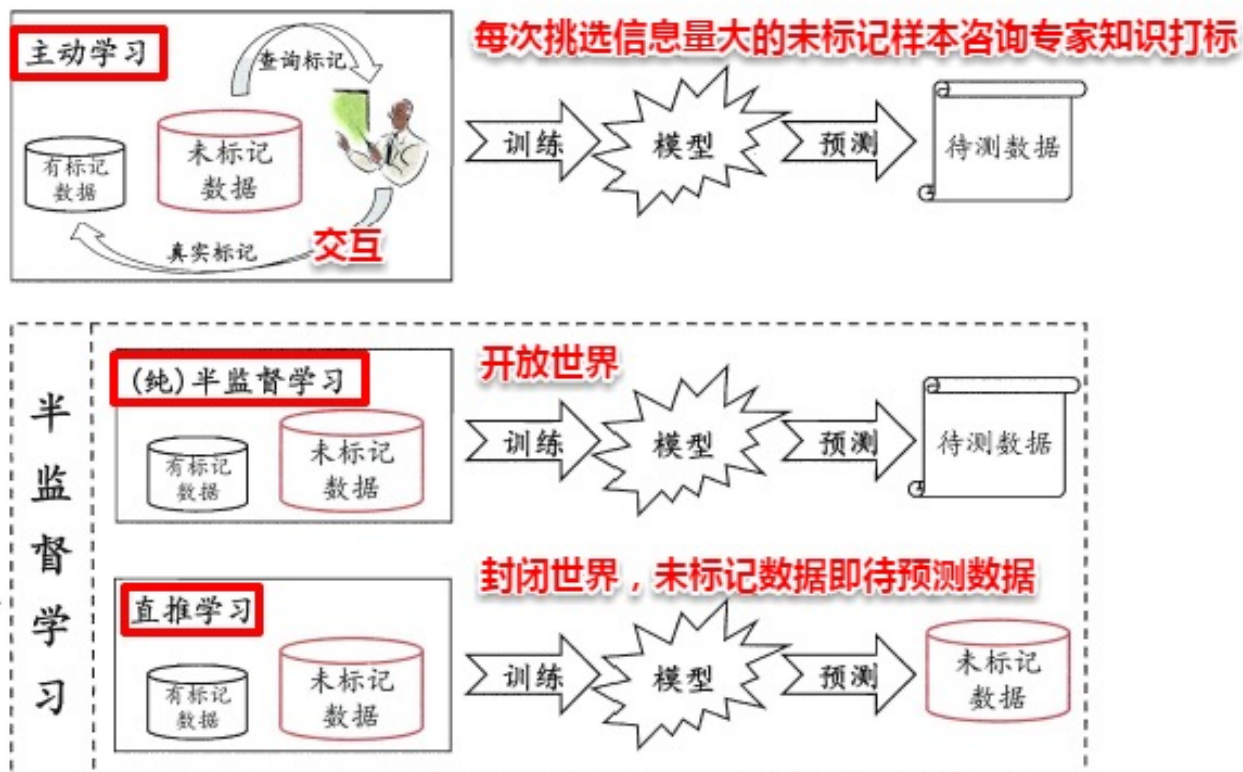
无监督的学习：无训练样本，仅根据测试样本的在特征空间分布情况进行标记，准确性差。

半监督的学习：有少量训练样本，学习机以从训练样本获得的知识为基础，结合测试样本的分布情况逐步修正已有知识，并判断测试样本的类别。

□ **主动学习：**需要与外界进行交互/查询/打标，其本质上仍然属于一种监督学习

● 半监督学习分为两类

- **纯半监督学习：**假定训练数据集中的未标记数据并非待预测数据
- **直推式学习：**学习过程中的未标记数据就是待预测数据




直推式学习得到的模型是针对特定测试样本定制化的模型

1. 半监督学习问题



训练集含有标记样本 $D_l = \{(x_1^l, y_1^l), (x_2^l, y_2^l), \dots, (x_n^l, y_n^l)\}$ 和未标记样本 $D_u = \{x_1^u, x_2^u, \dots, x_m^u\}$



标注数据少，无法判断！

加入无标签数据后，能够判断！

□ 半监督学习算法的成立依赖于假设：

- **聚类假设：**同一聚类中的样本点很可能具有同样的类别标记。关注样本空间的整体特征，探测样本分布稠密和稀疏的区域，从而更好地约束决策边界穿过稀疏区域
- **流形假设：**高维中的数据存在着低维的特性。利用大量的无标签样增加样本空间的密度，从而更准确地获取样本的局部近邻关系，是聚类假设的推广
- **平滑假设：**相似的样本具有相同的标签。

- 生成式方法
- Self-Training
- 半监督SVM
- 图半监督学习
- 基于分歧的方法
- 半监督聚类


2.1.生成式方法

➤ 模型的分类

依照模型的目标，模型可分为：

- ✓ 生成式模型：1、样本是怎么生成的，求解 $P(X)$
2、样本的标签是什么？求解 $P(Y|X)$
- ✓ 判别式模型：样本的标签是什么？求解 $P(Y|X)$


实例：高斯混合模型（GMM）与SVM



2.1.生成式方法

➤ 有监督的生成模型

- 给定带标签的训练实例 $x^r \in C_1, C_2$
 - 找最可能的先验概率 $P(C_i)$ 和观测概率 $P(x|C_i)$
 - $P(x|C_i)$ 由 μ^i 和 Σ 参数化的高斯分布




基于 $P(C_1), P(C_2), \mu^1, \mu^2, \Sigma$, 推测新样本属于 C_1 的概率

$$P(C_1|x) = \frac{P(x|C_1)P(C_1)}{P(x|C_1)P(C_1) + P(x|C_2)P(C_2)}$$

2.1.生成式方法

➤ 半监督的生成模型

- 给定带标签的训练实例 $x^r \in C_1, C_2$
 - 找最可能的先验概率 $P(C_i)$ 和观测概率 $P(x|C_i)$
 - $P(x|C_i)$ 由 μ^i 和 Σ 参数化的高斯分布



无标签数据 x^u 可以帮助重新估计 $P(C_1), P(C_2), \mu^1, \mu^2, \Sigma$

参数未知+样本属于哪一类的信息未知

2.1.生成式方法

➤ 半监督的生成模型

- 初始化: $\theta = \{P(C_1), P(C_2), \mu^1, \mu^2, \Sigma\}$
- E** • Step 1: 计算未标记数据的后验概率 $P_{\theta}(C_1|x^u)$
- M** • Step 2: 更新模型

算法最终收敛,
但初始化会影响结果

取决于模型 θ

Back to step 1

$$P(C_1) = \frac{N_1 + \sum_{x^u} P(C_1|x^u)}{N}$$

N : 例子的总数
 N_1 : 属于 C_1 的例子总数

$$\mu^1 = \frac{1}{N_1} \sum_{x^r \in C_1} x^r + \frac{1}{\sum_{x^u} P(C_1|x^u)} \sum_{x^u} P(C_1|x^u) x^u \dots\dots$$

2.1.生成式方法



$$\theta = \{P(C_1), P(C_2), \mu^1, \mu^2, \Sigma\}$$

- 标记数据的最大似然

Closed-form solution

$$\log L(\theta) = \sum_{x^r} \log P_{\theta}(x^r, \hat{y}^r)$$

$$\begin{aligned} P_{\theta}(x^r, \hat{y}^r) \\ = P_{\theta}(x^r | \hat{y}^r) P(\hat{y}^r) \end{aligned}$$

- 标记+未标记数据的最大似然

迭代求解

$$\log L(\theta) = \sum_{x^r} \log P_{\theta}(x^r, \hat{y}^r) + \sum_{x^u} \log P_{\theta}(x^u)$$

$$P_{\theta}(x^u) = P_{\theta}(x^u | C_1) P(C_1) + P_{\theta}(x^u | C_2) P(C_2)$$

(x^u 来自 C_1 或 C_2)

2.2.Self-Training

➤ 自训练算法

- 给定: 带标签数据集 = $\{(x^r, \hat{y}^r)\}_{r=1}^R$, 未标记数据集 $\{x^u\}_{u=l}^{R+U}$

- Repeat:

- 从标记数据集训练模型 f^*

根据需要进行选择合适模型

回归?

- 将 f^* 应用于未标记的数据集

- 获得 $\{(x^u, y^u)\}_{u=l}^{R+U}$

伪标签

- 从未标记数据集中移除一组数据, 并将它们添加到带标签数据集


How to choose the data set remains open

You can also provide a weight to each data.

2.2.Self-Training


➤ 自训练算法

- 类似于生成模型的半监督学习
 - 硬标签 v.s. 软标签
- 考虑使用神经网络
来自标记数据的 θ^* (网络参数)



2.2. Self-Training——熵正则化

□ 基于熵的正则化：限制 y^u 的分布，使其更集中



$$E(y^u) = -\sum_{c=1}^5 y_c^u \log y_c^u \quad y^u \text{ 的熵越小越好}$$


$$\text{Loss} = \sum_{x^l} \text{CE}(y^l, \hat{y}^l) \quad \text{有标签数据}$$

$$+ \lambda \sum_{x^u} E(y^u) \quad \text{无标签数据}$$

选择熵较小的无标签数据加入有标签集进行Self-Training

2.3.半监督SVM

□ **TSVM(Transductive SVM)**: 尝试为未标记样本找到合适的标记指派, 使得超平面划分后的间隔最大化 (低密度分割假设)



2.3. 半监督SVM



$$D = \{(x_1, y_1), \dots, (x_l, y_l), x_{l+1}, \dots, x_m\} \quad \{D_l, D_u\}$$

□ TSVM目标: 为 D_u 中的样本给出预测标记 $\hat{y} = (\hat{y}_{l+1}, \hat{y}_{l+2}, \dots, \hat{y}_m)$, $\hat{y}_i \in \{-1, +1\}$, 满足:

$$\min_{w, b, \hat{y}, \xi} \frac{1}{2} \|w\|_2^2 + C_l \sum_{i=1}^l \xi_i + C_u \sum_{i=l+1}^m \xi_i \rightarrow \text{松弛变量 hinge损失}$$

$$\text{s.t. } y_i(w^T x_i + b) \geq 1 - \xi_i, \quad i = 1, 2, \dots, l,$$

$$\hat{y}_i(w^T x_i + b) \geq 1 - \xi_i, \quad i = l+1, l+2, \dots, m,$$

$$\xi_i \geq 0, \quad i = 1, 2, \dots, m,$$

对应标记样本

对应未标记样本




图 6.4 软间隔示意图。红色圈出了一些不满足约束的样本。

C_l 与 C_u 用于平衡模型复杂度、有标记样本与未标记样本重要程度的折中参数

穷举每个无标签样本的预测标记计算复杂度过高, TSVM采用迭代策略


- $\xi_i = 0$, 分类正确, 支持向量恰好落在间隔边界上;
- $0 < \xi_i < 1$, 则分类正确, 支持向量在间隔边界与分离超平面之间;
- $\xi_i = 1$, 则支持向量在分离超平面上;
- $1 < \xi_i$, 则分类错误, 支持向量位于分离超平面误分类一侧。

2.3. 半监督SVM

□ **TSVM求解**: 迭代地进行局部搜索。分两个环节: 分配伪标记并获得初始SVM、交换错分的未标记样本更新SVM


1. 计算初始SVM

- 有标记样本训练SVM
- 获得未标记样本的伪标签后, 再训练SVM



2. 交换标记重复训练SVM

- 挑选两个可能错分的异类未标记样本
- 交换其标签, 重新训练SVM



挑选准则

- 减轻类别不平衡的影响, 基于伪标记而当作正反例的未标记样本数, 将 C_u 拆为 C_u^+ 、 C_u^-

$$C_u^+ = \frac{u_-}{u_+} C_u^-$$

输入: 有标记样本集 $D_l = \{(x_1, y_1), (x_2, y_2), \dots, (x_l, y_l)\}$;
未标记样本集 $D_u = \{x_{l+1}, x_{l+2}, \dots, x_{l+u}\}$;
折中参数 C_l, C_u .



过程:

- 1: 用 D_l 训练一个 SVM_l ; **初始SVM**
- 2: 用 SVM_l 对 D_u 中样本进行预测, 得到 $\hat{y} = (\hat{y}_{l+1}, \hat{y}_{l+2}, \dots, \hat{y}_{l+u})$;
- 3: 初始化 $C_u \ll C_l$;
- 4: **while** $C_u < C_l$ **do**
- 5: 基于 $D_l, D_u, \hat{y}, C_l, C_u$ 求解式(13.9), 得到 $(w, b), \xi$;
- 6: **while** $\exists \{i, j \mid (\hat{y}_i \hat{y}_j < 0) \wedge (\xi_i > 0) \wedge (\xi_j > 0) \wedge (\xi_i + \xi_j > 2)\}$ **do**
- 7: $\hat{y}_i = -\hat{y}_i$; **松弛变量越大表示离超平面越近, 越容易分错**
- 8: $\hat{y}_j = -\hat{y}_j$;
- 9: 基于 $D_l, D_u, \hat{y}, C_l, C_u$ 重新求解式(13.9), 得到 $(w, b), \xi$
- 10: **end while**
- 11: $C_u = \min\{2C_u, C_l\}$ **逐渐增大 C_u**
- 12: **end while**

输出: 未标记样本的预测结果: $\hat{y} = (\hat{y}_{l+1}, \hat{y}_{l+2}, \dots, \hat{y}_{l+u})$ **最终调整后的结果**


2.4.图半监督学习——平滑假设

- 平滑假设：相似的样本具有相同的标签
- 样本 x 的分布非均匀
- 若 x^1 和 x^2 在高密度区域相邻，则具有相同的标签




$x^1 x^2$ 具有相同标签
 $x^2 x^3$ 具有不同标签

$x^1 x^2$ are connected
 by a high density path



2.4.图半监督学习——平滑假设

- 方法一：聚类后作标记



要求聚类做得好

- 方法二：引入图结构

2.4.图半监督学习



□ 如何判断样本在高密度区域相邻?

——使用图结构描述样本点


□ 如何构建图?

1. 具有自然的图结构: 网页链接、论文引用.....
2. 从数据构建图:


- 计算样本之间的相似度 $s(x^i, x^j) = \exp(-\gamma \|x^i - x^j\|^2)$
- 将K近邻相连
- 将相似度小于某阈值的样本相连



- 边的权重正比于 $s(x^i, x^j)$



高斯径向基函数:






$$s(x^i, x^j) = \exp(-\gamma \|x^i - x^j\|^2)$$

2.4.图半监督学习

➤图半监督学习的基本思想

□ **节点标签扩散**：将已标记样本根据样本特征的相似性进行扩散，获得未标记样本的标记。




2.4.图半监督学习

➤图半监督学习的定量分析

□ 能量函数：定性评价图的平滑性

$$E = \frac{1}{2} \sum_{i,j} w_{i,j} (y^i - y^j)^2 = \mathbf{y}^T L \mathbf{y}$$

对于所有样本进行计算（包括有标签数据和无标签数据），**越小越好**



$\mathbf{y}$: 所有样本的标预测标签 $(R + U)$ 维

$$\mathbf{y} = [\dots y^i \dots y^j]^T \quad \mathbf{y} = (\mathbf{y}_l^T, \mathbf{y}_u^T)$$

L : 图拉普拉斯矩阵 $(R + U) \times (R + U)$ 维

$$L = D - W$$

$$(W)_{ij} = \begin{cases} \exp\left(\frac{-\|\mathbf{x}_i - \mathbf{x}_j\|_2^2}{2\sigma^2}\right), & \text{if } i \neq j; \\ 0, & \text{otherwise,} \end{cases}$$

$$W = \begin{bmatrix} 0 & 2 & 3 & 0 \\ 2 & 0 & 1 & 0 \\ 3 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix} \quad D = \begin{bmatrix} 5 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 \\ 0 & 0 & 5 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

2.4.图半监督学习



□ 求解：1. 作为正则项，使用梯度下降求解

$$E = \frac{1}{2} \sum_{i,j} w_{i,j} (y^i - y^j)^2 = \mathbf{y}^T L \mathbf{y} \quad \text{Loss} = \sum_{x^l} CE(y^l, \hat{y}^l) + \lambda E$$

□ 求解：2. 解析解

设 $\mathbf{y}$ 由判别函数 f 求得，即 $y_i = \text{sign}(f(x_i))$ ， $f = (f_l^T, f_u^T)$ ，可令 $E = f^T L f$

写成分块矩阵形式： $E(f) = (\mathbf{f}_l^T \ \mathbf{f}_u^T) \left(\begin{bmatrix} \mathbf{D}_{ll} & \mathbf{0}_{lu} \\ \mathbf{0}_{ul} & \mathbf{D}_{uu} \end{bmatrix} - \begin{bmatrix} \mathbf{W}_{ll} & \mathbf{W}_{lu} \\ \mathbf{W}_{ul} & \mathbf{W}_{uu} \end{bmatrix} \right) \begin{bmatrix} \mathbf{f}_l \\ \mathbf{f}_u \end{bmatrix} \quad (L = D - W)$

最小化能量函数： $\frac{\partial E(f)}{\partial \mathbf{f}_u} = \mathbf{0}$ 解得： $\mathbf{f}_u = (\mathbf{D}_{uu} - \mathbf{W}_{uu})^{-1} \mathbf{W}_{ul} \mathbf{f}_l$.

令 $\mathbf{P}_{uu} = \mathbf{D}_{uu}^{-1} \mathbf{W}_{uu}$, $\mathbf{P}_{ul} = \mathbf{D}_{uu}^{-1} \mathbf{W}_{ul}$ 则 $\mathbf{f}_u = (\mathbf{I} - \mathbf{P}_{uu})^{-1} \mathbf{P}_{ul} \mathbf{f}_l$

代入 D 、 W 、 $\mathbf{f}_l$ 即可求得 $\mathbf{f}_u$

2.5.基于分歧的方法

□ 多视图数据：一个数据对象有多个属性集，每个属性集构成了视图。

- 样本 $(\langle x^1, x^2 \rangle, y)$ ，其中 x^i 为样本在视图 i 中的示例， y 为标记
- 例如电影中的声音和视频分别对应一个视图，类型则为“动作片”、“纪录片”等

□ 多视图具有相容性，进而具有互补性

- 不同视图输出空间是一致的，以电影为例，类别均应为{纪录片、动作片}
- 故可利用多视图的互补性加强分类的准确性


2.5.基于分歧的方法



□ 协同训练：基于两个充分且条件独立的视图，利用未标记数据相互促进。


- 充分：每个视图均包含产生最优学习器的信息
- 条件独立：给定类别标记条件下，两个视图独立

- 基于标记样本训练视图模型1
- 以模型1挑选出该视图最确信的未标记样本赋予其伪标记，并将以上伪标记样本作为新的标记样本加至视图模型2的训练集
- 对视图2模型进行训练，进而挑出该视图模型最确信的未标记样本赋予其伪标记，将其加至视图模型1的训练集
- 重复以上两步，直到两个分类器不变



2.5.基于分歧的方法

协同训练算法



研究表明，协同训练无需多视图数据，只要保证多个弱学习器之间有显著分歧即可

输入：有标记样本集 $D_l = \{(\langle x_1^1, x_1^2 \rangle, y_1), \dots, (\langle x_l^1, x_l^2 \rangle, y_l)\}$;
未标记样本集 $D_u = \{\langle x_{l+1}^1, x_{l+1}^2 \rangle, \dots, \langle x_{l+u}^1, x_{l+u}^2 \rangle\}$;
缓冲池大小 s ;
每轮挑选的正例数 p ;
每轮挑选的反例数 n ;
基学习算法 $\mathcal{L}$;
学习轮数 T .

过程：

- 1: 从 D_u 中随机抽取 s 个样本构成缓冲池 D_s ;
- 2: $D_u = D_u \setminus D_s$;
- 3: for $j = 1, 2$ do
- 4: $D_l^j = \{(\langle x_i^j, y_i \rangle) \mid (\langle x_i^j, x_i^{3-j} \rangle, y_i) \in D_l\}$; 各视图的有标记样本
- 5: end for
- 6: for $t = 1, 2, \dots, T$ do
- 7: for $j = 1, 2$ do
- 8: $h_j \leftarrow \mathcal{L}(D_l^j)$; 基于每个视图训练初始学习器
- 9: 考察 h_j 在 $D_s^j = \{\langle x_i^j, x_i^{3-j} \rangle \mid \langle x_i^j, x_i^{3-j} \rangle \in D_s\}$ 上的分类置信度 挑选 p 个正例置信度最高的样本 $D_p \subset D_s$ 、 n 个反例置信度最高的样本 $D_n \subset D_s$;
- 10: 由 D_p^j 生成伪标记正例 $\tilde{D}_p^{3-j} = \{(\langle x_i^{3-j}, +1 \rangle \mid x_i^j \in D_p^j)\}$;
- 11: 由 D_n^j 生成伪标记反例 $\tilde{D}_n^{3-j} = \{(\langle x_i^{3-j}, -1 \rangle \mid x_i^j \in D_n^j)\}$;
- 12: $D_s = D_s \setminus (D_p \cup D_n)$; 两个学习器挑选的不会有重复
- 13: end for
- 14: if h_1, h_2 均未发生改变 then
- 15: break
- 16: else
- 17: for $j = 1, 2$ do
- 18: $D_l^j = D_l^j \cup (\tilde{D}_p^j \cup \tilde{D}_n^j)$; 加入打过伪标的未标记样本
- 19: end for
- 20: 从 D_u 中随机抽取 $2p + 2n$ 个样本加入 D_s 补充缓冲池
- 21: end if
- 22: end for

输出：分类器 h_1, h_2 最终输出两个分类器做集成


2.6.半监督聚类

□ 拥有部分额外监督信息时：可利用监督信息改善聚类效果。

□ 两种监督信息：

- 约束：必连（实线）与勿连（虚线）

- 少量有标签样本



2.6.半监督聚类



□ 约束K-均值算法

输入: 样本集 $D = \{x_1, x_2, \dots, x_m\}$;
必连约束集合 $\mathcal{M}$;
勿连约束集合 $\mathcal{C}$;
聚类簇数 k .

过程:

1: 从 D 中随机选取 k 个样本作为初始均值向量 $\{\mu_1, \mu_2, \dots, \mu_k\}$;

2: repeat

3: $C_j = \emptyset$ ($1 \leq j \leq k$);

4: for $i = 1, 2, \dots, m$ do

5: 计算样本 x_i 与各均值向量 μ_j ($1 \leq j \leq k$) 的距离: $d_{ij} = \|x_i - \mu_j\|_2$;

6: $\mathcal{K} = \{1, 2, \dots, k\}$;

7: is_merged=false;

8: while $\neg$ is_merged do

9: 基于 $\mathcal{K}$ 找出与样本 x_i 距离最近的簇: $r = \arg \min_{j \in \mathcal{K}} d_{ij}$;

10: 检测将 x_i 划入聚类簇 C_r 是否会违背 $\mathcal{M}$ 与 $\mathcal{C}$ 中的约束;

11: if $\neg$ is_violated then

12: $C_r = C_r \cup \{x_i\}$;

13: is_merged=true

14: else

15: $\mathcal{K} = \mathcal{K} \setminus \{r\}$; 若不满足则寻找距离次小的类簇

16: if $\mathcal{K} = \emptyset$ then

17: break并返回错误提示

18: end if

19: end if

20: end while

21: end for

22: for $j = 1, 2, \dots, k$ do

23: $\mu_j = \frac{1}{|C_j|} \sum_{x \in C_j} x$;

24: end for


25: until 均值向量均未更新

输出: 簇划分 $\{C_1, C_2, \dots, C_k\}$


对样本进行划分时, 需检测是否满足约束关系, 其它步骤均相同

在标准K-Means算法中加入对约束的检测, 依次判断距离无标签样本最近的簇是否满足约束


● 西瓜数据集4.0,施加若干必连和勿连约束, 聚类迭代过程




(a) 第1轮迭代后



(c) 第3轮迭代后



(b) 第2轮迭代后



(d) 第4轮迭代后

2.6.半监督聚类



□ 少量有标记样本的聚类算法

输入: 样本集 $D = \{x_1, x_2, \dots, x_m\}$;
少量有标记样本 $S = \bigcup_{j=1}^k S_j$;
聚类簇数 k .

过程:

```
1: for  $j = 1, 2, \dots, k$  do
2:    $\mu_j = \frac{1}{|S_j|} \sum_{x \in S_j} x$ 
3: end for
4: repeat
5:    $C_j = \emptyset$  ( $1 \leq j \leq k$ );
6:   for  $j = 1, 2, \dots, k$  do
7:     for all  $x \in S_j$  do
8:        $C_j = C_j \cup \{x\}$ 
9:     end for
10:  end for
11:  for all  $x_i \in D \setminus S$  do
12:    计算样本  $x_i$  与各均值向量  $\mu_j$  ( $1 \leq j \leq k$ ) 的距离:  $d_{ij} = \|x_i - \mu_j\|_2$ ;
13:    找出与样本  $x_i$  距离最近的簇:  $r = \arg \min_{j \in \{1, 2, \dots, k\}} d_{ij}$ ;
14:    将样本  $x_i$  划入相应的簇:  $C_r = C_r \cup \{x_i\}$ 
15:  end for
16:  for  $j = 1, 2, \dots, k$  do
17:     $\mu_j = \frac{1}{|C_j|} \sum_{x \in C_j} x$ ;
18:  end for
19: until 均值向量均未更新
输出: 簇划分  $\{C_1, C_2, \dots, C_k\}$ 
```

使用带标记样本各类别的均值向量作为初始类中心


带标记样本直接划入对应类簇

划分无标记样本


重新计算类中心

先根据有标记样本初始化聚类中心, 再使用K-Means算法划分无标记样本


● 西瓜数据集4.0, 假定部分样本类别已知




(a) 第1轮迭代后



(b) 第2轮迭代后



(b) 第2轮迭代后




(d) 第4轮迭代后

@yan

□ XX-Match

- **一致性正则：**给输入加入扰动，模型的输出应该尽可能保持不变或者近似
 - 注入 noise 可以通过模型本身的随机性（如 dropout）或者直接加入噪声，也可以通过 data augmentation；计算一致性的方法，可以使用 L2，也可以使用 KL divergency、cross entropy。
- **熵最小化：**要求预测近似于one-hot标签




MixMatch:

多次数据增强后取平均预测
作为伪标签

- **MixMatch:** A Holistic Approach to Semi-Supervised Learning
- **ReMixMatch:** Semi-Supervised Learning with Distribution Alignment and Augmentation Anchoring
- **FixMatch:** Simplifying Semi-Supervised Learning with Consistency and Confidence, NeurIPS 2020

□ Self-supervised based SSL

- 使用自监督方法（无监督学习的一个分支）进行预训练，再使用有标签数据进行微调




Big Self-Supervised Models:

先试用自监督学习进行预训练
再使用有监督学习进行微调
最后在半监督数据集上进行Self-Training


- S4L: Self-Supervised Semi-Supervised Learning
- Big Self-Supervised Models are Strong Semi-Supervised Learners, NeurIPS 2020

4. 相关文献



Introduction to Semi-Supervised Learning

Xiaojin Zhu and
Andrew B. Goldberg



Semi-Supervised Learning

Chapelle Olivier;
Scholkopf Bernhard;
Zien Alexander

视频教学:

https://www.youtube.com/watch?v=fX_guE7JNnY&list=PLJV_el3uVTsPy9oCRY30oBPNLCo89yu49&index=14

相关资料汇总: <https://github.com/yassouali/awesome-semi-supervised-learning>

• 本章小结

- 建立无标记样本利用的概念
- 高斯混合模型实现赋予未标记样本伪标签
- Self-Training: 自我迭代确定伪标签
- TSVM法利用局部搜索异类错分未标记样本迭代求近似解
- 图半监督学习: 二分类的扩散方法和多类情况的迭代传播算法
- 基于分歧的方法: 多视图协同训练
- 半监督聚类: 先验约束和部分标记样本