

華中科技大學

自主智能系統


— 智能感知技術（三維感知）

馬杰

三维目标检测识别

从三维数据
中检测识别
感兴趣目标。

检测：分割
识别：分类




多阶段方案：先检测，后识别



●**优点：**分为**目标分割、目标识别、避免小目标漏检测**

●**缺点：**两任务**单独进行、无相互作用、耗时较多**

单阶段方案：同时检测&识别





●**优点：**相互作用**多任务**，**提高整体运行效率**

●**缺点：**点云数据**网络输入**表示，点云数据特点调整**网络结构**

基于特征的三维目标检测技术（双阶段）


真实环境下，激光雷达成像同时包含目标和背景数据，在复杂背景下，如何检测到目标，如何分割完整的目标点云，往往比目标识别本身更有挑战性。



- ❑ **地面目标：** 由于受到地形地貌、植被遮蔽等环境因素的影响，检测难度高；
- ❑ **水面目标：** 需要排除水面非目标的干扰，相对地面目标的检测而言容易一些。
- ❑ **空中目标：** 天空背景，相对单一，检测较为容易；


没有一种算法可以适应所有场景，需要根据背景、目标、需求等要素，进行专门设计

Step1 点云分割-地面背景滤除




扩大窗口高程阈值滤波 (Elevation Threshold with Expanding Window Filter)

基于局部坡度的点云滤波，根据地形和地貌的不同自动设置参数，通过滑动窗口，处理整个场景。




扩大窗口高程阈值滤波算法是用一个不断扩大的窗口来确定和去掉非地面点的方法。

Step2 点云聚类-提取目标3D框



扫描激光雷达属于等角度成像，距离分辨率随测量距离变化差异较大，采用固定阈值欧式距离聚类效果不佳。




分层次欧式距离聚类


雷达点云属于等角度成像 θ ，那么随着距离增大，点云逐渐稀疏 $L \cdot \tan(\theta)$ 。

避免：近处目标的误聚类，远处目标的过分割。 可以将点云数据划分成不同区域，采取不同参数进行聚类。

如果为了照顾远处目标，阈值设置过大，两个紧挨的近距离目标会误聚类。反之则带来过分割。




(a)欧式距离聚类算法




(b)分层次欧式距离聚类

根据激光雷达角分辨率大小，待检测目标大小设置阈值范围。且远处阈值大，近处阈值小。


分割试验结果




(a)A平地场景




(b)B森林场景




(c)C工厂场景




(d)D城区场景




(a)A1



(b)A2



(c)A3



(d)A4

准确率70%的情况下，召回率95%

场景	场景中 真实坦克	0.1m 分辨率 检测坦克 数	0.15m 分辨率检 测坦克数	0.2m 分辨率检 测坦克数	0.3m 分辨率检 测坦克数	0.4m 分辨率检 测坦克数
场景1	2	2	2	2	2	2
场景2	4	3	4	3	3	3
场景3	4	3	2	4	4	4
场景4	4	4	4	4	4	3
场景5	3	3	3	3	3	3
场景6	4	4	4	4	4	4
场景7	4	4	4	4	4	4
场景8	4	4	4	4	3	3
场景9	5	5	5	5	5	5
场景10	4	4	4	4	4	3


$$Precision = \frac{TP}{TP+FP}$$

$$Recall = \frac{TP}{TP+FN}$$


思考：检测阶段，准确率优先还是召回率优先？

Step3 虚警滤除（目标粗分类）

- 由于目标包围盒提取的几何特征作为浅层特征本来就具有可分性，同时对于每个点云目标其表现形式为多维向量，因此采用深度较浅的全连接多层感知机（MLP）网络模型可以提取高层语义信息完成目标识别，消除虚警（假目标）。

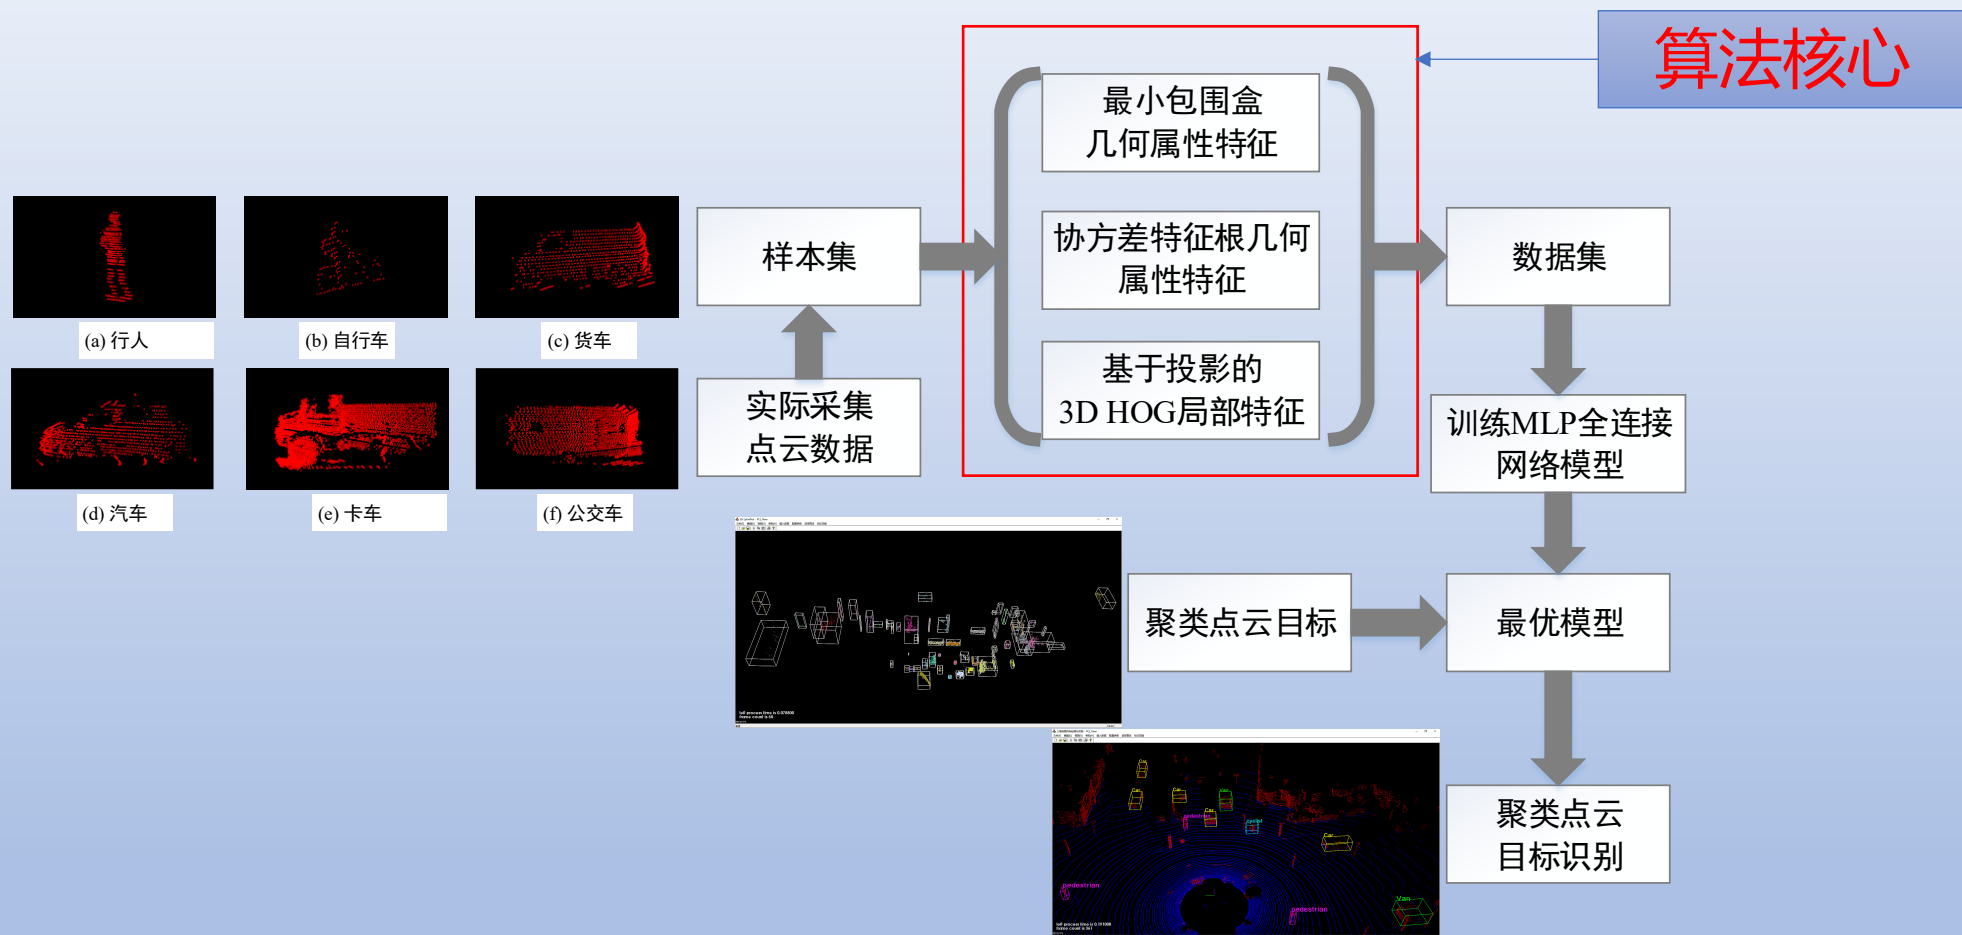


目标分割




MLP

基于MLP网络模型的三维目标分类算法



算法流程：首先**提取点云目标特征**然后标注点云目标作为样本，提取其自定义特征制作数据集，最后基于该特征数据集训练**MLP全连接网络模型**完成目标识别

最小包围盒特征



点云目标的最小包围盒几何特征：长度 L 、宽度 W 、高度 H ，
长宽比特征 L/W ，长高比特征 L/H ，最后整合得到

$$F_{bbox} = \{L, W, H, L/W, L/H\}$$

$$|F_{bbox}| = 5$$

反映了目标外轮廓属性 5D

协方差特征

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

$$\bar{y} = \frac{1}{N} \sum_{i=1}^N y_i$$

$$\bar{z} = \frac{1}{N} \sum_{i=1}^N z_i$$

$$\text{Cov}(\mathbf{X}, \mathbf{Y}) = E[(\mathbf{X} - E(\mathbf{X}))(\mathbf{Y} - E(\mathbf{Y}))] = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})$$

$$\mathbf{C} = \begin{bmatrix} \text{Cov}(\mathbf{X}, \mathbf{X}) & \text{Cov}(\mathbf{X}, \mathbf{Y}) & \text{Cov}(\mathbf{X}, \mathbf{Z}) \\ \text{Cov}(\mathbf{Y}, \mathbf{X}) & \text{Cov}(\mathbf{Y}, \mathbf{Y}) & \text{Cov}(\mathbf{Y}, \mathbf{Z}) \\ \text{Cov}(\mathbf{Z}, \mathbf{X}) & \text{Cov}(\mathbf{Z}, \mathbf{Y}) & \text{Cov}(\mathbf{Z}, \mathbf{Z}) \end{bmatrix}$$

对协方差矩阵 $\mathbf{C}$ 利用SVD分解进行特征值求解

$$\mathbf{C}\mathbf{V} = \mathbf{E}\mathbf{V}$$

特征值向量

$$\mathbf{E} = \{\lambda_1, \lambda_2, \lambda_3 (\lambda_1 > \lambda_2 > \lambda_3)\}$$

反映了整体表面分布属性 8D

线性

$$K_{\text{linearity}} = \frac{\lambda_1 - \lambda_2}{\lambda_1}$$

平面度

$$K_{\text{planarity}} = \frac{\lambda_2 - \lambda_3}{\lambda_1}$$

分散度

$$K_{\text{scattering}} = \frac{\lambda_3}{\lambda_1}$$

散乱度

$$K_{\text{variance}} = (\lambda_1 \times \lambda_2 \times \lambda_3)^{\frac{1}{3}}$$

曲率度

$$K_{\text{curvature}} = \frac{\lambda_3}{\lambda_1 + \lambda_2 + \lambda_3}$$

各向异性

$$K_{\text{anisotropy}} = \frac{\lambda_1 - \lambda_3}{\lambda_1}$$


特征熵

$$K_{\text{entropy}} = \lambda_1 \times \log(\lambda_1) + \lambda_2 \times \log(\lambda_2) + \lambda_3 \times \log(\lambda_3)$$

朝向性

$$K_{\text{orientation}} = \begin{cases} 1, \Delta z < \Delta x \text{ \& \& } \Delta z < \Delta y \\ 0, \text{others} \end{cases}$$

精细特征提取 3D HOG (Histogram of Oriented Gradient)




投影图像归一化到 (40*40) : HOG特征中单元cell取为8*8个像素、局部块block取为2*2个cell、梯度方向数bin取为9, 每个图得到的HOG特征维度为4*4*(4*9) = 576维

$$F_{hog3d} = \{H_{xy}, H_{xz}, H_{yz}\}$$

$$|F_{hog3d}| = 1728$$

反映了各个投影面高度分布属性 1728D

MLP全连接网络模型




网络输入特征


$$\mathbf{F}_{typical} = \{\mathbf{F}_{bbox}, \mathbf{F}_{eigen}, \mathbf{F}_{hog3d}\}$$
$$|\mathbf{F}_{typical}| = 1741$$

$$5+8+1728$$

■原始点云




■地面目标检测效果




训练样本示例




(a) 行人




(b) 自行车




(c) 货车




(d) 汽车



(e) 卡车



(f) 公交车




评价指标	类别						
	汽车	货车	卡车	公交车	自行车	行人	其他
召回率 (%)	95.04	88.15	86.55	82.42	71.14	77.01	94.67
精确率 (%)	90.17	84.03	83.06	81.52	86.18	83.23	89.87

约300毫秒/帧

3D目标识别方法（基于特征）


优点：可控制、可理解
缺点：参数复杂
难点：提高速度



三维描述子概述

描述子：对三维特征进行描述的向量



主要分为全局描述子和局部描述子两类。



3D descriptors		
Name	Type	Size [†]
PFH (Point Feature Histogram)	Local	125
FPFH (Fast Point Feature Histogram)	Local	33
RSD (Radius-Based Surface Descriptor)	Local	289
3DSC (3D Shape Context)	Local	1980
USC (Unique Shape Context)	Local	1960
SHOT (Signatures of Histograms of Orientations)	Local	352
Spin image	Local	153*
RIFT (Rotation-Invariant Feature Transform)	Local	32*
NARF (Normal Aligned Radial Feature)	Local	36
RoPS (Rotational Projection Statistics)	Local	135*
VFH (Viewpoint Feature Histogram)	Global	308
CVFH (Clustered Viewpoint Feature Histogram)	Global	308
OUR-CVFH (Oriented, Unique and Repeatable Clustered Viewpoint Feature Histogram)	Global	308
ESF (Ensemble of Shape Functions)	Global	640
GFPFH (Global Fast Point Feature Histogram)	Global	16
GRSD (Global Radius-Based Surface Descriptor)	Global	21

基于描述子的目标识别

通过**关键点选择**，**关键点特征描述**，**特征描述子匹配**。把三维目标识别问题转换成**模型与场景**特征之间的相似性度量问题。



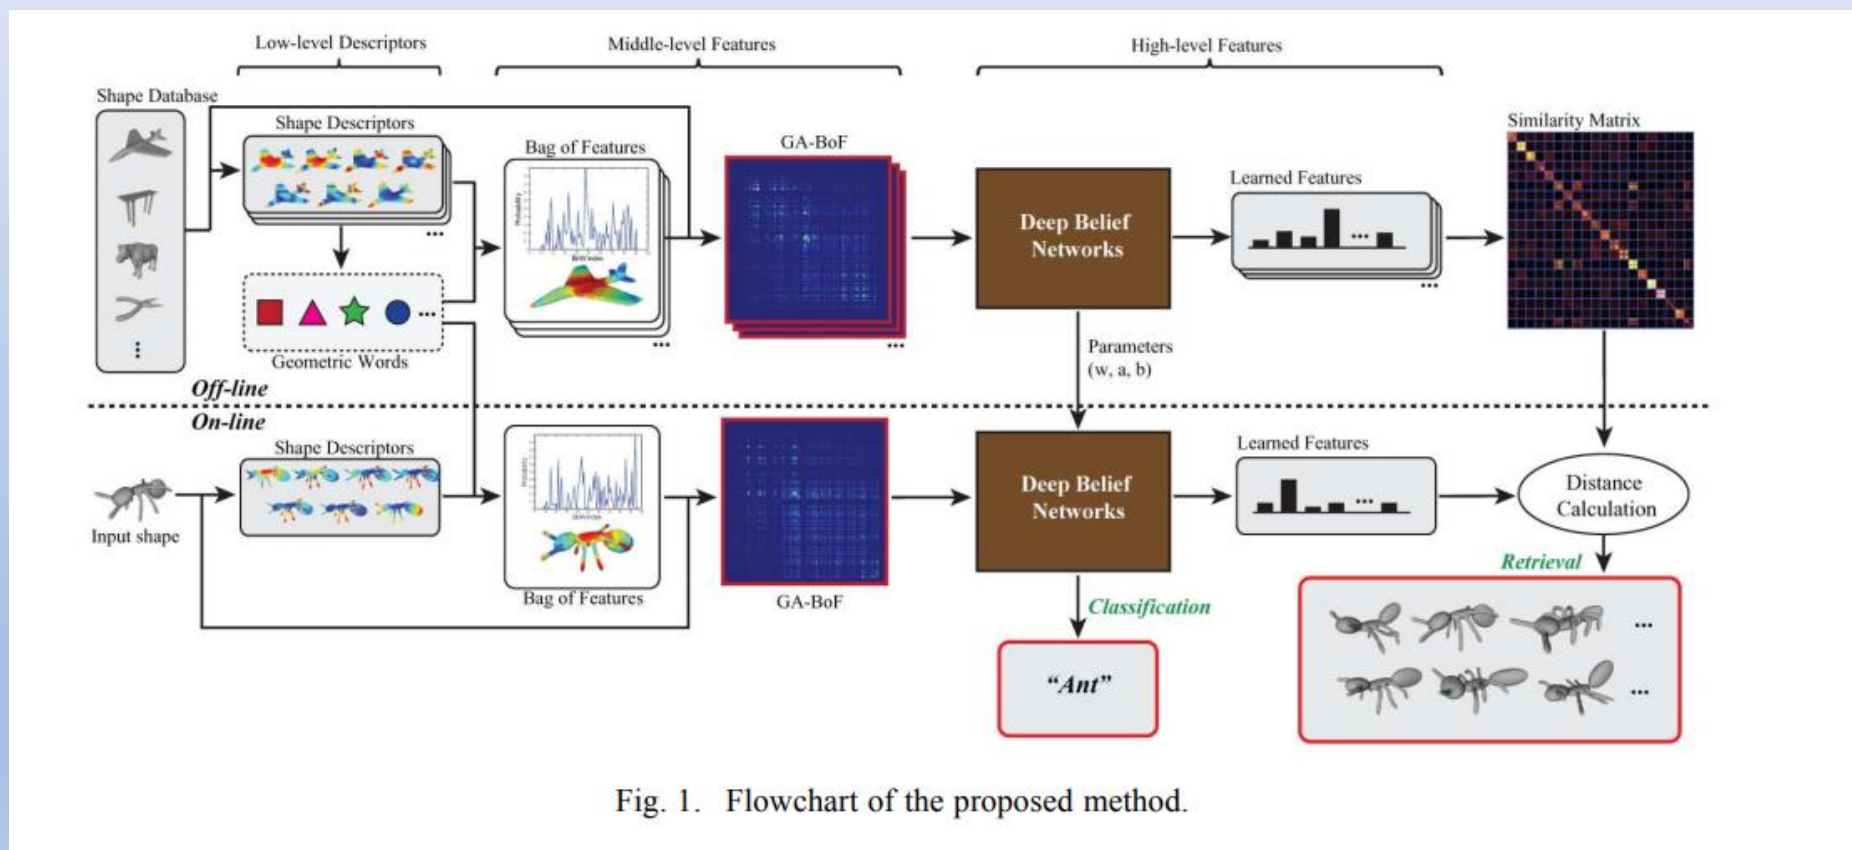
3D目标识别方法（基于学习）

优点：速度、潜力
缺点：训练集、黑盒子
难点：散乱点云数据组织



Based on Handcrafted descriptors


Learning High-Level Feature by Deep Belief Networks for 3-D Model Retrieval and Recognition
(IEEE TRANSACTIONS ON MULTIMEDIA 2014)



几何单词提取 + 特征词袋 + 深度置信网络 + 特征距离判别

Based on Multiple-view Rendering




Multi-view Convolutional Neural Networks for 3D Shape Recognition (ICCV-2015)



多方向投影+ CNN1 + 视点池化 + CNN2

Based on a 3D voxel grid


3D ShapeNets: A Deep Representation for Volumetric Shapes(CVPR-15)



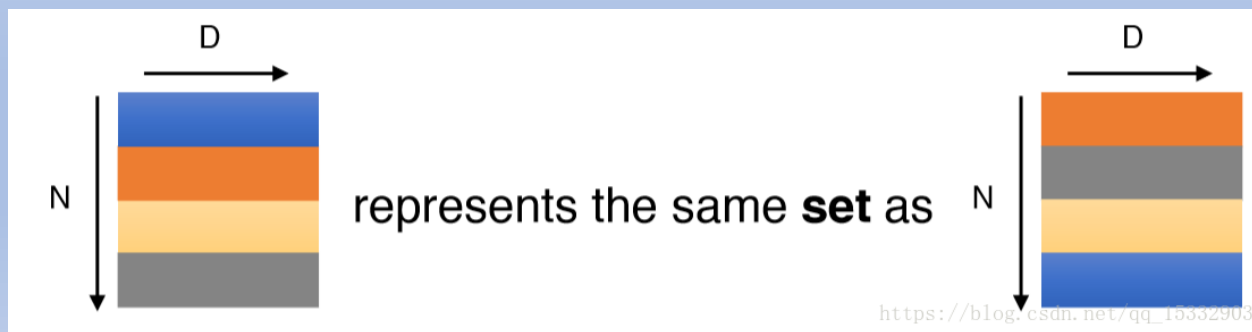
将3D形状表示为voxel网格二值变量的概率分布，构造了一个卷积DBN，学习输入x和label y的联合分布 26

Based on original data


无序性：点云本质上是一长串点（ $n \times 3$ 矩阵，其中 n 是点数）。在几何上，点的顺序不影响它在空间中对整体形状的表达，但是，相同的点云可以由两个完全不同的矩阵表示



我们希望得到的效果： N 代表点云个数， D 代表每个点的特征维度。不论点云顺序怎样，希望得到相同的特征提取结果。





无序性问题



- x 代表点云中某个点， h 代表特征提取层， g 叫做对称方法， γ 代表更高维特征提取，最后接一个softmax分类。
- g 可以是maxpooling或sumpooling，即最后的D维特征对每一维都选取N个点中对应的最大特征值或特征值总和，这样就可以通过 g 来解决无序性问题。

旋转性问题


- 相同的点云在空间中经过一定的刚性变化（旋转或平移），坐标发生变化，我们希望不论点云在怎样的坐标系下呈现，网络都能正确的识别出。这个问题可以通过STN（spacial transform network）来解决。



STN能够自适应的学到对于不同数据的空间变换方式。它不仅可以对输入数据进行空间变换,同样可以作为网络模块插入到现有网络的任意层中实现对不同Feature map的空间变换。最终让网络模型学习了对平移、尺度变换、旋转和扭曲的不变性。

PointNet


首次将深度学习直接应用与点云
斯坦福大学Charles R. Qi等 2017



输入为三通道点云数据，也可以有额外的通道比如颜色、法向量等，对于目标分类任务，输出类别。对于语义分割任务，输出每个点相对于各类别的分数。

PointNet

maxpooling解决无序性问题：
网络对每个点进行了一定程度的特征提取之后，对点云的整体提取出global feature。



全局特征
用来识别

STN解决旋转问题：pointnet采用了两次STN，第一次是对空间中点云进行调整，第二次feature transform是对提取出的特征进行对齐。

局部和全局信息的融合用来分割

Figure 2. **PointNet Architecture.** The classification network takes n points as input, applies input and feature transformations, and then aggregates point features by max pooling. The output is classification scores for k classes. The segmentation network is an extension to the classification net. It concatenates global and local features and outputs per point scores. “mlp” stands for multi-layer perceptron, numbers in bracket are layer sizes. Batchnorm is used for all layers with ReLU. Dropout layers are used for the last mlp in classification net.

代表性方法

算法名称	提出年份	核心思想与技术路径	主要贡献与影响
PointNet / PointNet++	2017	基于点 (Point-based)	开创了直接处理无序点云的深度学习范式。
VoxelNet	2018	基于网格 (Grid-based) — 体素	引入3D体素化与特征编码，实现端到端检测。
PointRCNN	2019	基于点 (Point-based)	首个基于点的两阶段检测器，直接在点云中生成和优化3D候选框。
PointPillars	2019	基于网格 (Grid-based) — 柱体	创新性地使用柱体表示，将点云转换为2D伪图像，极大提升推理速度。
PV-RCNN	2020	点-体素混合 (Point-Voxel Hybrid)	提出混合架构，同时保留体素特征的效率和点云几何信息的精度。
CenterPoint	2021	基于点 (Point-based)	将目标检测转化为关键点检测任务，简化流程并提升性能。
BEVFormer	2022	鸟瞰图 (BEV) + Transformer	利用Transformer在BEV空间中融合多模态及时序信息，引领新范式。
VoxelNeXt	2023	基于网格 (Grid-based) — 体素	在纯稀疏卷积框架下，仅凭3D体素特征实现SOTA精度，模型更简洁高效。

点云处理中不同数据结构对比

- 体素：结构最清晰。2.5D稀疏点云放到3D稠密空间
- 投影：2.5D-2D，信息损失，多视图投影又带来冗余
- 点云：保留原始信息，但是非结构化数据处理难。

维度	基于点云	基于体素	基于投影（BEV）
几何精度	高（保留原始结构）	中（受量化误差影响）	低（高度信息被压缩）
计算速度	低（邻域搜索慢）	中高（稀疏卷积加速）	高（纯2D卷积）
内存占用	高（存储完整点云）	中（网格化存储）	低（2D特征图）
易优化程度	难（非结构化）	中（依赖稀疏算子）	易（成熟2D框架）
小物体检测	好	中（取决于体素大小）	好（只要高度可区分）
典型场景	高精地图、学术研究	自动驾驶、通用检测	嵌入式设备、实时系统

当前主流趋势是**混合架构**（如PV-RCNN），兼顾速度和精度。

PV-RCNN





Figure 2. The overall architecture of our proposed PV-RCNN. The raw point clouds are first voxelized to feed into the 3D sparse convolution based encoder to learn multi-scale semantic features and generate 3D object proposals. Then the learned voxel-wise feature volumes at multiple neural layers are summarized into a small set of key points via the novel voxel set abstraction module. Finally the keypoint features are aggregated to the RoI-grid points to learn proposal specific features for fine-grained proposal refinement and confidence prediction.


由voxel_based得到的高质量proposals，然后再利用Point_based的方法获得精细的局部信息。

多模态融合



现有趋势是融合检测，发挥点云图像**互补优势**，提高三维检测的整体性能；

RGB-D融合




互补性:

图像: 细节丰富, 便于识别, 但是缺乏距离信息;

点云: 包含场景三维结构信息, 但是存在稀疏特性;

融合的第一步：外参标定





思考：

图像和点云中的关键点一一对应吗？

为了有效地融合雷达相机数据，需要精确标定雷达相机系统的外参数。该外参数是雷达坐标系到相机坐标系的刚体变换矩阵，由一个旋转矩阵 R 和一个平移向量 T 构成。雷达相机系统标定后，相机图像和雷达点云是像素级对齐的。

激光雷达相机系统外参数标定





难点：需要拥有规则形状的三维几何体作为2D-3D的标定物体。且要求尺寸大、数量多。

我们提出一个新的基于标定物的雷达相机系统标定算法。在这个方案中，我们采用一种“**主要标定物+辅助标定物**”的组合标定方案。

主要标定物定义为尺寸已知的带有棋盘图案的矩形板；辅助标定板定义为尺寸未知的多边形板；

主要标定物提供3D-3D和3D-2D的约束；辅助标定物提供3D-2D的约束；它们能够提高标定精度

激光雷达相机系统外参数标定



使用“主要标定物+辅助标定物”的标定方法后，我们方法的标定精度优于已有的标定方法。



Geometric calibration for LiDAR-camera system fusing 3D-2D and 3D-3D point correspondences

Pei An, Tao Ma, Kun Yu, Bin Fang, Jun Zhang, Wenxing Fu, and Jie Ma

Opt. Express 28(2) 2122-2141 (2020)

[HTML](#)

[PDF](#)




Optics EXPRESS

[AUTHOR INFORMATION](#) [SUBMIT YOUR MANUSCRIPT](#) [CREATE E-ALERTS](#) [FOLLOW@OSPUBLISHING](#)

TOP download

雷达-相机融合应用：深度补全





难点：图像纹理-三维结构并非一一对应。

有没有解决方法？

出发点：激光雷达的角分辨率有限，不利于雷达系统的后续应用（比如稠密三维重建，3D目标检测）。因此，**为了提高三维点云分辨率**，能否利用稠密的图像信息，来对点云数据进行深度补全。


基于朗伯体反射的图像-点云跨域约束





朗伯定律：小表面区域上，特定方向上的反射能量与该方向与表面法线之间的角度余弦成正比。

该方法主要分为四步：

- 1, 根据深度图，计算稀疏法线图（准确）；
- 2, 通过局部法线光照约束（LBN约束），获得稠密法线图；
- 3, 根据稀疏深度图，估计粗糙的稠密深度图；
- 4, 根据稠密法线图和粗糙稠密的深度图，使用引导滤波器（Guided Filter），获得稠密且准确的深度图。



雷达相机系统应用：深度补全




自动驾驶多模态传感器

	技术方案	测距	测速	测角	点云密度	恶劣天气 (雨雪雾) 适应性	强光/弱 光适应性	噪点抑制 能力	成本
激光雷 达	dToF 905nm	优	弱	优	优	中	中	良	中
	dToF 1550nm		弱			较高			
	iToF 1550nm (FMCW)		优			中	优	很高	
毫米波 雷达	3D	良	优	良	低	优	优	中	低
	4D				中				
	4D成像 (FMCW)				良				
	4D成像 (PMCW)	优			优			高	
摄像头	可见光, 单目	中	弱	中	优	弱	弱	优	低
	可见光, 双目	良	中						中
	长波红外热成像	中	弱						中
超声波 雷达	40KHz, 短距UPA	很弱	弱	弱	低	中	优	中	很低
	60KHz, 长距APA	弱							低

多模态融合方法

- 通常有三种方式
- 前期融合（数据级）：具有最好的融合时机。但是不同传感器的数据具有不同的特点（物理意义、分辨率、维度。。。），使用相同的网络对这些数据进行处理并不合理。
- 深度融合（特征级）：使用两个不同的网络来进行特征提取。然后在将这两个特征进行融合，具有灵活、高效的优点，难点在于如何设计合适的特征空间，特征之间如何聚合（图像特征和点云特征权重分配？）。
- 后融合（决策级）：不同数据通过各自的网络独自处理，结果进行融合。后期融合算法紧凑、直观，便于网络编码。但是后期的融合只会减少而不是产生新的检测，所以重要的是要调整输入检测器，使其召回率最大化，而不是精确度。

SC-SSD: 点云图像融合的三维目标检测 (数据级融合)



- 1, 通过空间感知融合模块 (SMF Module) 获取体素化的RGB点云数据;
- 2, 通过稀疏残差编码器 (SR Encoder), 获取富有判别性的体素特征;
- 3, 通过级联注意力机制的检测头 (CA Detector), 得到目标对象的3D包围框和置信度。

RGB-D 单阶段3D目标检




在KITTI数据集上，排名前十的目标检测算法一览表（3D Detection）（2020年5月）

	Method	Setting	Code	Moderate	Easy	Hard	Runtime	Environment
1	MMLab PV-RCNN		code	81.43 %	90.25 %	76.82 %	0.08 s	1 core @ 2.5 Ghz (Python + C/C++)
S. Shi, C. Guo, L. Jiang, Z. Wang, J. Shi, X. Wang and H. Li: PV-RCNN: Point-Voxel Feature Set Abstraction for 3D Object Detection . CVPR 2020.								
2	OAP			80.63 %	89.18 %	73.04 %	0.06 s	1 core @ 2.5 Ghz (C/C++)
3	Associate-3Ddet v2			80.25 %	90.93 %	74.85 %	0.04 s	1 core @ 2.5 Ghz (Python)
4	3D-CVF at SPA			80.05 %	89.20 %	73.11 %	0.06 s	1 core @ 2.5 Ghz (C/C++)
J. Yoo, Y. Kim, J. Kim and J. Choi: 3D-CVF: Generating Joint Camera and LiDAR Features Using Cross-View Spatial Feature Fusion for 3D Object Detection . arXiv preprint arXiv:2004.12636								
5	CN			79.89 %	90.55 %	76.31 %	0.04 s	GPU @ 2.5 Ghz (Python + C/C++)
6	SA-SSD		code	79.79 %	88.75 %	74.16 %	0.04 s	1 core @ 2.5 Ghz (Python)
C. He, H. Zeng, J. Huang, X. Hua and L. Zhang: Structure Aware Single-stage 3D Object Detection from Point Cloud . CVPR 2020.								
7	STD		code	79.71 %	87.95 %	75.09 %	0.08 s	GPU @ 2.5 Ghz (Python + C/C++)
Z. Yang, Y. Sun, S. Liu, X. Shen and J. Jia: STD: Sparse-to-Dense 3D Object Detector for Point Cloud . ICCV 2019.								
8	AAMF-SSD			79.59 %	88.97 %	72.51 %	0.05 s	GPU @ 2.5 Ghz (Python)
9	3DSSD		code	79.57 %	88.36 %	74.55 %	0.04 s	GPU @ 2.5 Ghz (Python + C/C++)
Z. Yang, Y. Sun, S. Liu and J. Jia: 3DSSD: Point-based 3D Single Stage Object Detector . CVPR 2020.								
10	Point-GNN		code	79.47 %	88.33 %	72.29 %	0.6 s	GPU @ 2.5 Ghz (Python)
W. Shi and R. Rajkumar: Point-GNN: Graph Neural Network for 3D Object Detection in a Point Cloud . CVPR 2020.								

排KITTI榜单的第八名；单独就单阶段目标检测而言，我们的网络排KITTI榜单的第二。

3D-CVF: 点云图像融合的三维目标检测 (特征级融合)

针对激光点云和RGB图像, 分别使用两个骨干网络提取它们的特征




利用自适应门控融合网络, 获得融合特征, 得到初始的三维目标框

对于三维目标框中的关键点, 融合精细图像特征和精细点云特征, 回归出准确的三维目标框

- 阶段一 (RPN阶段) 阶段二 (RCNN阶段) : 。

3D-CVF: 栅格点融合特征的提取



从整体角度看，3D-CVF是点云图像融合的双阶段检测方法的范例

把三维框的栅格点投影在图像上，根据图像特征图获得栅格点的图像特征；栅格点的图像特征和点云特征“拼接起来”，在精细回归网络（Refinement network）中，回归出精确的三维框参数

3D-CVF: KITTI数据集表现


Method	Modality	Runtime (ms)	3D AP (%)		
			AP_{Easy}	$AP_{Mod.}$	AP_{Hard}
VoxelNet [31]	LiDAR	220	77.47	65.11	57.73
SECOND [28]	LiDAR	50	83.13	73.66	66.20
PointPillars [9]	LiDAR	16.2	79.05	74.99	68.30
PointRCNN [22]	LiDAR	100	85.94	75.76	68.32
Fast PointRCNN [3]	LiDAR	65	85.29	77.40	70.24
Patches [10]	LiDAR	150	88.67	77.20	71.82
Part A ² [23]	LiDAR	80	87.81	78.49	73.51
STD [30]	LiDAR	80	87.95	79.71	75.09
MV3D [12]	LiDAR+RGB	240	71.09	62.35	55.12
AVOD [8]	LiDAR+RGB	80	73.59	65.78	58.38
F-PointNet [17]	LiDAR+RGB	170	81.20	70.39	62.19
AVOD-FPN [8]	LiDAR+RGB	100	81.94	71.88	66.38
UberATG-ContFuse [13]	LiDAR+RGB	60	82.54	66.22	64.04
RoarNet [24]	LiDAR+RGB	100	83.95	75.79	67.88
UberATG-MMF [12]	LiDAR+RGB	80	88.40	77.43	70.22
Our 3D-CVF	LiDAR+RGB	75	89.20	80.05	73.11

Camera-LiDAR Object Candidates (CLOCs) (决策级融合)

决策级融合的三维目标检测 (IROS 2020, 机器人顶会) 思想简单值得借鉴


出发点:

- 图像数据是密集的，点云数据是稀疏的。如果强制的将图像的特征向量和点云的特征向量变换到相同的大小，然后对其进行拼接，聚合以及平均等操作，这并不能很好的融合不同传感器的特征。



- 如果一个目标同时被2D和3D检测，那么，将3D的检测框投影到图片平面上，他们的检测框将会高度重合。

CLOCs: 决策级点云图像融合的三维目标检测



CLOC的核心在于校正3D目标框置信度的方法:


- 1) Geometric-consistency (几何一致性): 3D框与2D框的IoU交并比大于阈值, 就认为该3D框与2D框配对
- 2) Semantic-consistency (语义一致性): 对于图像和点云的检测器而言, 存在多种类别的输出, 对应目标框的类别一致才进行融合。

CLOCs: 决策级点云图像融合的三维目标检测

KITTI数据集表现

Detector	Input Data	3D AP (%)			Bird's Eye View AP (%)		
		easy	moderate	hard	easy	moderate	hard
SECOND (baseline) [6]	LiDAR	83.34	72.55	65.82	89.39	83.77	78.59
CLOCs_SecCas (SECOND+Cascad R-CNN)	LiDAR+Img	86.38	78.45	72.45	91.16	88.23	82.63
<i>Improvement (CLOCs_SecCas over SECOND)</i>	-	+3.04	+5.90	+6.63	+1.77	+4.46	+4.04
PointRCNN (baseline) [8]	LiDAR	86.23	75.81	68.99	92.51	86.52	81.39
CLOCs_PointCas (PointRCNN+Cascad R-CNN)	LiDAR+Img	87.50	76.68	71.20	92.60	88.99	81.74
<i>Improvement (CLOCs_PointCas over PointRCNN)</i>	-	+1.27	+1.04	+2.21	+0.09	+2.47	+0.35
PV-RCNN (baseline) [22]	LiDAR	87.45	80.28	76.21	91.91	88.13	85.41
CLOCs_PVCas (PV-RCNN+Cascad R-CNN)	LiDAR+Img	88.94	80.67	77.15	93.05	89.80	86.57
<i>Improvement (CLOCs_PVCas over PV-RCNN)</i>	-	+1.49	+0.39	+0.94	+1.14	+1.67	+1.17
F-PointNet [24]	LiDAR+Img	82.19	69.79	60.59	91.17	84.67	74.77
AVOD-FPN [12]	LiDAR+Img	83.07	71.76	65.73	90.99	84.82	79.62
F-ConvNet [25]	LiDAR+Img	87.36	76.39	66.69	91.51	85.84	76.11
UberATG-MMF [26]	LiDAR+Img	88.40	77.43	70.22	93.67	88.21	81.99
UberATG-ContFuse [14]	LiDAR+Img	83.68	68.78	61.67	94.07	85.35	75.88

CLOCs: 决策级点云图像融合的三维目标检测



如何避免召回率下降？ CLOCs对单模态检测器使用较低的置信度阈值，这样会生成大量候选框（包括虚警），随后CLOCs通过学习几何和语义一致性，筛选出其中的真正目标。

思考

- 复杂场景下三维目标识别技术是学术前沿和热点，存在很多的问题需要解决，主要分为以下几点。
 - 1) 精度、噪声问题：可识别准则？
 - 2) 遮挡、空洞问题：不能避免，能否利用？
 - 3) 分辨率问题：稀疏，分布不均匀，算法？
 - 4) 变形问题：运动、局部变形，算法+结构？
 - 5) 计算量大：硬件？投影，体素，点云，其他？