

2026/04/01

自主智能系统中的路径规划

蔡超

华中科技大学人工智能与自动化学院

多谱信息智能处理技术全国重点实验室

(逸夫科技楼 1104 , 计算机视觉实验室 caichao@hust.edu.cn)

CONTENTS

目录

01

第一节：自主智能
系统与规划基础

02

第二节：任务规划
方法

03

第三节：路径规划
算法

04

第四节：动态环境
与现代方法

CONTENTS

目录

05

课程总结

06


参考资料与扩展
阅读

07


课后思考题

01

第一节：自主智能系统 与规划基础



1.1 自主智能系统概述




自主智能系统定义

指能在无人或最小人工干预下，感知环境、做出决策并执行任务的智能系统。



自主智能系统核心与应用

核心特征为感知、认知、决策、执行的闭环能力，典型应用有移动机器人、自动驾驶、无人机、智能仓储系统。



自主系统的关键技术栈

自主系统关键技术栈分为五层：感知层（传感器）、建模层（环境表示）、规划层（任务/路径规划）、控制层（运动控制）、执行层（执行器）

1.2任务规划三层架构




任务规划层

任务规划层：将自然语言/符号化目标分解为带执行顺序、约束的可执行子任务序列




路径规划层

路径规划层：依据起止位置、环境地图，在配置空间生成无碰撞几何路径点序列。




运动规划层

运动规划层：输入几何路径、动力学模型，输出时间参数化轨迹，毫秒级响应，分层规划有多方面优势




1.3任务/路径规划的应用领域

(1) 汽车导航




规划的应用领域

(2) 机器人任务-路径规划





复杂环境机器人 任务规划





路径规划的应用领域

(3) 机械臂路径（轨迹）规划




(4) 手术导引与路径规划



手术导航技术

跟踪定位手术器械的空间位置，并结合医学成像技术将手术器械的位置在病人的医学图像上显示出来，使医生能够清楚的观察到手术器械相对于人体器官或病灶的具体位置，从而辅助医生进行临床手术。




经皮肾镜
取石术



华中科技大学

HUAZHONG UNIVERSITY OF SCIENCE AND TECHNOLOGY

(5) 无人机航迹规划






(6) 水下无人航行器航路规划



思考与总结

什么时候进行规划？





设置

60%

12:13



不喜欢下雨... || ▶

SOS 求助

37

km/h

正在向左变道



剩余41.0公里 预计63分钟后到达

目的地：珞喻路关山口公交站

1. 4环境建模



栅格图 (image)：将空间离散为规则网格，单元标记自由/占据，2D环境适配性好，需权衡分辨率与内存。

为了便于存储和读取，大幅面地图常采用八叉树/四叉树 (Octree/Quadtree) 等自适应分辨率的层次化表示。空旷区域用大单元，复杂区域细分。

优点：内存高效，适合3D环境



矢量图 (map)：用点、线、面（多边形）等几何要素描述





图 (Graph)

将环境抽象为节点（关键位置）和边（连通性）的图结构，高层规划效率高，但丢失几何细节。




环境数据管理

数字高程模型 (digital elevation model, DEM)




地图三维显示





地形高程图栅格表示

● 起始点
▲ 目标点



环境立体障碍
物的栅格表示







激光点云数据

环境地图模型栅格表示 ESDF-欧几里得符号距离场

障碍物



障碍物
ESDF
距离场




实时查询无人机到障碍物的距离信息。

矢量数据管理(拓扑图)


DEM digital elevation model

DSM digital surface model

DTM digital terrain model





带有纹理贴图的三维地形





隧道、洞穴三角格网显示


海图的S57 数据标准和 S52显示标 准



环境要素建模及矢量数据管理



雷达威胁源模型



防空火力模型在水平面上是一半径在 $R_{D_{\max}}^j$ 和 $R_{D_{\min}}^j$ 之间的圆环, 在竖直方向上是有最大作用高度 $H_{H_{\max}}^j$ 和最小作用高度 $H_{H_{\min}}^j$ 之间的区域, 导弹在 (x_i, y_i, h_i) 处, 当 $H_{\min}^j < h_j < H_{\max}^j$ 时受到的威胁为:

$$TabPK(x_i, y_i, h_i) = \begin{cases} 0, & 0 \leq R < R_{D_{\min}}^j \\ K \frac{R_{\max} - R}{R_{\max}}, & R_{D_{\min}}^j \leq R \leq R_{D_{\max}}^j \\ 0, & R > R_{\max}^k \end{cases}$$

其中导弹在航路点 i 处飞行过程中被第 j 个雷达探测到的瞬时发现概率为:

$$p_t^i = \begin{cases} \frac{1}{1 + \left(\frac{c_2 R_i^4}{\sigma} \right)^{c_1}} & \text{if } \text{is not} \\ 0 & \text{if in Radarblind} \end{cases}$$

其中, R_i 是导弹在航路点 i 处距离雷达威胁源中心的位置, σ 是导弹的雷达截面积。

移动威胁模型

▣在一定作战范围，移动威胁源随机出现



$$\begin{cases} x - x_0^2 + y - y_0^2 \leq R^2 \\ p_{x,y} = \frac{1}{\pi R^2} \\ R = VT \end{cases}$$

▣目标在已知路径上行进，
同时可以估计前进方向和速度

$$x_t = x_0 + vt$$

$$y_t = y_0 + vt$$


$$f_{xy} = \frac{L_{threat}}{2\pi\sqrt{\det(K)}} \exp\left[-\frac{1}{2}(X - X_t)^T K^{-1}(X - X_t)\right]$$






矢量栅格混合环境数据管理

飞行环境包括了威胁区域、禁飞区域、雷达测高区域、景象匹配区域等区域，其中的威胁区又因为威胁源的不同，其分布范围、动态特性、威胁等级各有差异，需要建立多种环境模型。环境模型的表达方式应该兼顾到精确性和简洁性，应该结合具体的优化算法把环境模型融入到规划空间中。

集地图信息、专题图信息、环境信息、目标信息为一体,结合复杂多约束信息和飞行任务要求,建立适用于任务规划算法的规划空间。这里的关键是矢量图和栅格图的多尺度融合管理技术,既解决矢量图全部转化为栅格图的庞大数据量和精度下降问题,又解决矢量图碰撞检测过程的冗余计算问题。










地物特征与模型

战场环境构成



1.5基本原理与概念



状态空间 (State Space) 是指系统所有可能状态的集合。在航迹规划问题中，状态通常包括智能体的**位置、速度、姿态等运动学信息**。将状态空间离散化后，规划问题可被转化为在状态空间图上寻找从初始状态到目标状态路径的问题。

配置空间 (Configuration Space, C-space) 是状态空间在机器人运动规划领域中的具体体现。对于一个机器人在二维空间中的运动，配置空间即为所有可达位置的集合；当存在障碍物时，配置空间被划分为自由空间（可行区域）和障碍空间（禁止区域）。

决策空间 (Decision Space) 是智能体在所有状态下可采取的行动集合，在航迹规划中通常称为**动作空间 (Action Space)**。决策空间中的每一个动作对应状态空间中的一次状态转移，其代价决定了规划路径的评价基础

多目标问题

$$\min_{\tau, u(\cdot), T} \mathbf{J}(\tau) = [J_1(\tau), J_2(\tau), \dots, J_K(\tau)]$$

路径

满足：

$$\dot{x}(t) = f(x(t), u(t)), \quad x(t) \in X_{\text{free}}, \quad u(t) \in U,$$

状态空间

动作/控制空间

$$g(x(t), u(t), t) \leq 0, \quad h(x(t), u(t), t) = 0$$

动力（运动）学方程

$$x(0) = x_{\text{init}}, \quad x(T) \in X_{\text{goal}}.$$

02

第二节：任务规划 (TASK PLANNING)、 任务-运动规划 (TASK AND MOTION PLANNING, TAMP)



2.1 经典任务规划




符号规划

基于逻辑推理的规划方法
状态用命题或谓词表示
动作作用前置条件和效果描述



STRIPS表示

STRIPS动作Pick(object, location): 前置条件为机器人、物体在目标位置且抓手空, 效果为抓取物体、物体离位、抓手非空。



PDDL语言

PDDL是规划领域标准描述语言, 分离领域与问题定义, 支持多类扩展, 多用于机器人任务规划



经典规划算法

经典规划算法包含: 前向搜索、后向搜索、启发式搜索、GraphPlan、SAT/CSP求解器

2.2 层次化任务网络 (HTN)



HTN规划原理

HTN规划以方法为分解规则，将复杂任务递归拆解，直至所有任务转化为原始动作。



HTN的组成要素

HTN的组成要素包括：任务（抽象任务或原始动作）、方法（任务分解规则）、操作符（原始动作的STRIPS式描述）



HTN vs 经典规划

搜索空间：经典规划为状态空间，HTN规划为任务分解空间

领域知识：经典规划少，HTN规划丰富

效率：经典规划低，HTN规划高

灵活性：经典规划高，HTN规划中等




应用场景

制造业流程规划

军事任务规划

游戏AI（如《星际争霸》）



ZZ方案智能生成系统

2.3现代任务规划：LLM驱动的规划：大语言模型在任务规划中的应用（2026年前沿）

自然语言到任务序列

输入自然语言指令（如"把桌上的杯子放到厨房"），经LLM理解意图后，输出结构化动作序列。

LLM+PDDL架构

LLM负责高层推理与任务分解，PDDL求解器管形式化验证和优化，行为树掌执行控制


优势与挑战

优势：可处理模糊指令、具备常识推理能力、能快速适配新任务

挑战：可靠性验证难、易幻觉、计算成本高



2.4任务与运动规划集成 (TAMP)



TAMP的必要性

传统方法任务与运动规划分离，易出现任务可行但运动不可行问题，TAMP可同时兼顾符号与几何约束。



TAMP框架

高层任务目标 ↓ 符号规划器
↔ 几何可行性检查 ↓ 运动规划器
↓ 可执行轨迹




关键技术

延迟约束求解
增量式规划
基于采样的TAMP
学习辅助的TAMP

03

第三节：路径规划算法



3.1 飞行器约束条件模型


- 1) 飞行器自身特性约束条件建模方法研究；
- 2) 飞行器制导控制约束条件建模方法研究。

转弯约束

$$\frac{a_i^T a_{i+1}}{|a_i| |a_{i+1}|} \geq \cos(\phi)$$


$$R_{\min} = \frac{V^2}{g\sqrt{n_y^2 - 1}}$$

n_y 为飞行器过载




无人机最大俯仰角约束

$$\beta_i = \arctan \frac{(z_{i+1} - z_i)}{\sqrt{(x_{i+1} - x_i)^2 + (y_{i+1} - y_i)^2}} \leq \beta_{\max}, (i = 1, 2, \dots, N)$$




飞行器导航约束



飞行器约束条件

飞行器约束条件总体架构



3.2 路径规划的多目标优化问题

(1) 基于动力学模型的控制参数规划




- ◆ **优点**：具有比较好的理论基础，可以给出优化航迹和控制参数
- ◆ **不足**：难以适应复杂环境和约束

$$\dot{\mathbf{x}}(t) = \mathbf{f}(t, \mathbf{x}(t), \mathbf{u}(t))$$

$$\min_{t_0, t_F, \mathbf{x}(t_0), \mathbf{x}(t_F)} J_B(t_0, t_F, \mathbf{x}(t_0), \mathbf{x}(t_F)) + \int_{t_0}^{t_F} J_P(\tau, \mathbf{x}(\tau), \mathbf{u}(\tau)) d\tau$$

(2) 基于运动学方程的状态参数规划

- ◆ **优点**：具有很强的路径搜索能力。
- ◆ **不足**：输出的航迹与控制量无关，需要控制器实现路径跟随。



多目标问题

$$\min_{\tau, u(\cdot), T} \mathbf{J}(\tau) = [J_1(\tau), J_2(\tau), \dots, J_K(\tau)]$$

路径

满足：

$$\dot{x}(t) = f(x(t), u(t)), \quad x(t) \in X_{\text{free}}, \quad u(t) \in U,$$

状态空间

动作/控制空间

$$g(x(t), u(t), t) \leq 0, \quad h(x(t), u(t), t) = 0$$

动力（运动）学方程



$$x(0) = x_{\text{init}}, \quad x(T) \in X_{\text{goal}}.$$

简单的飞行器二维航迹规划示例


```
X = [3, n] = [x;y;psi] = state = [pos; pos; angle];  
                %状态参数位置 (x,y) 航向角 (th)  
dpsi=g/V*tan(u); %滚转角到航向角变化率关系,u为  
                控制量滚转角  
  
dx = V*cos(psi);  
dy = V*sin(psi);
```

无人飞行器
运动学模型

$$\begin{cases} \dot{x} = v \cos \psi \\ \dot{y} = v \sin \psi \\ \dot{\psi} = g \tan \gamma / v \end{cases}$$



3.3多目标优化问题的帕雷托最优解集 (PARETO OPTIMAL SOLUTION SET)



帕雷托最优解及帕雷托前沿示意图

3.4多目标优化转化为单目标优化

常用方法

规划分析代价模型


$$\begin{aligned} \min \quad & y = F(x) = (f_1(x), f_1(x), \dots, f_M(x)) \\ \text{s.t.} \quad & g_i(x) \leq 0, \quad i = 1, 2, \dots, p \\ & h_j(x) = 0, \quad j = 1, 2, \dots, q \\ & x = (x_1, x_2, \dots, x_D) \in \Omega \subset R^D \\ & y = (y_1, y_2, \dots, y_M) \in \Lambda \subset R^M \end{aligned}$$

$$f(X) = \omega_1 f_1(X) + \omega_2 f_2(X) + \omega_3 f_3(X) + \omega_4 f_4(X)$$


$$J(Z) = \omega_1 J_{lengh} + \omega_2 J_{hazard} + \omega_3 J_{smooth} + \omega_4 J_{mach}$$

3.5 路径表示方法

- ① 一种是Dubins曲线，即以节点、直线和圆弧表示飞行路径；



② 采用BeZier或B样条等曲线对路径进行拟合处理的表示方法，B样条曲线让拟合之后更加光滑。




优点

- 1) 贝塞尔曲线具有凸包特性，即贝塞尔曲线被完全地限制在控制点所组成的凸包内。
- 2) 贝塞尔曲线对时间微分所得到的曲线仍然是贝塞尔曲线，且新曲线的控制点可以用原有曲线的控制点表示


缺点

- 1) 缺乏局部修改性，即改变某一控制点对整个曲线都有影响。
- 2) n 较大时，特征多边形的边数较多，对曲线的控制减弱。
- 3) 幂次过高难于修改。（而在外形设计中，局部修改是随时要进行的）。



B样条 (**B-spline**) 曲线

B样条曲线是一般化的贝塞尔曲线。与贝塞尔曲线不同的是，B样条曲线能够进行局部调整，控制点调整所带来的影响是局部的，不会影响整条曲线的变化



S 为起始点， T 为目标点， $P_1, P_2, P_3, \dots, P_n$ 为航迹的中间导航点。每两个导航点之间的连线为一个航迹段。航迹中的任意导航点都包含多种属性，包括地球坐标系下的位置信息、导航点类型、姿态信息、代价信息等

3.6、常用的规划方法及优化算法


3.6.1 从规划空间模型建立的角度来考虑，
常用的航路规划方法有：

单元分解法（Cell decomposition）法；


路线图构造（Roadmap construction）法；

人工势函数（Artificial potential function）法。

a、单元分解法 (Cell decomposition) 法




(a) 对象依赖法



(b) 栅格法


基于单元分解(Cell Decomposition)的规划方法首先将自由的C空间分解成为一些简单的单元，并判断这些单元之间是否是连通的(存在可行路径)，寻找一系列连通的单元将起始单元和目标单元连接起来即可。

在对象依赖的单元分解中，障碍物的边界被用作单元的边界，这样所有单元并在一起恰好与自由空间重合（如右图所示）。对象依赖单元分解的另一个优点就是分解得到的单元数目较少，节省存储空间。但其分解过程较为复杂，各单元之间是否存在包含、交叉、连接、相邻关系的判断比较困难。Keil和Sack于1985年证明，对于具有缺口的多边形，如何将它分解成凸多边形的组合是一个NP问题。




对象依赖法

在对象独立的单元分解过程中，首先将C空间分解为规则形状的单元（通常为正方形），然后检查各单元是否被障碍物覆盖或与障碍物相交。由于所有单元都是预先划分的，其形状和位置不随对象的形状和位置而改变，单元的边缘与对象的边缘也不一定重合，但其误差随着单元的细化而不断减少。与对象依赖单元分解相比，在实际应用中该方法的计算量要小得多。栅格法和四叉树法是最常用的两种对象独立单元分解方法。




栅格法




四叉树法


B、路线图构造 (ROADMAP CONSTRUCTION)法



通视图




Voronoi图



随机路线图

在基于路线图 (Skeleton , Roadmap) 的航迹规划方法中, 首先根据一定规则将自由的C空间(Configuration Space)表示成一个由一维的线段构成的网络图, 然后采用某一搜索算法在该网络图上进行航迹搜索。这样, 路径规划问题被转化为一个网络图的搜索问题。


通视图由规划空间中的障碍物的相互可见的顶点间的连线构成。右图显示了包含三个多边形障碍物的二维规划空间的通视图，其中较粗的线表示起始点S和目标点G之间的一条最短路径。1989年，Asano等证明在具有 n 个顶点的二维规划空间中，其通视图的边数具有数量级 $O(n^2)$ ，构造通视图所需时间的数量级也为 $O(n^2)$



通视图




如果运动物体要求与障碍
(或威胁)的距离越远越好,
可以采用Voronoi 图方法。
Voronoi 图由与两个或多
个障碍(或威胁)的给定特
征元素距离相等的点的集
合构成。Voronoi 图的边
数数量级 $O(n)$, 构造
Voronoi 图所需时间的数
量级为 $O(n\log n)$, 其中 n 为
所选特征元素数目。



Voronoi图



随机路线图法由Overmars等于1992年率先提出。该方法通过在规划空间中随机进行采样生成路线图，然后在该路线图中搜索路径。随机路线图的构造如下：如果最新的采样点与路线图中的某一节点间存在可行路径，则将该采样点加入到路线图中，同时找出该节点与路线图中的近邻节点间可能存在的路径，并将可行路径作为节点间的边加入到路线图中。



随机路线图


该方法的优点之一就是可以在规划时间和路径的质量之间进行权衡，构造随机路标图的时间越长，得到最优路径的可能性就越大。在确定环境下，随机路标图一般可以事先构造。然而，如果规划环境一旦发生变化，随机路标图并不能通过局部更新以适应新的环境，因此，该算法一般不适于在线实时应用。

动态节点优化航迹网络优化



C、人工势函数 (ARTIFICIAL POTENTIAL FUNCTION) 法

人工势场法最先由Khatib[6]于上世纪80年代中期提出，它不需要利用图形的形式表示规划空间，而是将物体的运动看成是两种力作用的结果：一种是吸引力，它将运动物体拉向目标点；一种是排斥力，它使运动物体远离障碍物和威胁源。这样，物体总是沿着合力的方向运动。



3.6.2从航路规划优化搜索算法上来分， 常用的优化搜索算法有：




在实际的搜索过程中，当存在大面积遮挡或者自身有较强约束时，算法可能陷入局部搜索，A*的回退机制无法保证能够及时跳出局部搜索

进化算法对全局的把握能力较强，通过进化操作可以和快实现航迹的变化，避免的反复的局部搜索，但是容易陷入局部最优

(1) 扩展类搜索算法

a、Dijkstra算法

Dijkstra算法是典型最短路算法，用于计算一个节点到其他所有节点的最短路径。主要特点是以起始点为中心向外层层扩展，直到扩展到终点为止。Dijkstra算法能得出最短路径的最优解，但由于它遍历计算的节点很多，所以效率低。





Dijkstra's Algorithm

B、 A*搜索算法


A*搜索算法是一种启发式最优搜索方法，它通过预先确定的代价函数决定当前应扩展的节点。A*算法对当前节点的每一个可能扩展的节点计算代价，然后选择最低代价的扩展节点加入搜索空间来搜索。加入搜索空间的这一新节点又被用来产生更多的可能扩展节点。A*搜索算法的代价函数形式如下：

$$f(x) = g(x) + h(x)$$

其中 $g(x)$ 项为从起始位置到当前位置 x 的真实代价， $h(x)$ 为从当前位置 x 到目标位置代价的估计值。在 A*算法扩展的每一步都将选择具有最小 $f(x)$ 值的节点插入到可能路径的链表中。已经证明，如果当前节点到目标点的真实代价 $h^*(x)$ 总大于或者等于预估代价 $h(x)$ ，即 $h^*(x) \geq h(x)$ ，A*搜索算法就能找到一条最优的路径



A*算法流程图




1. 生成两个空列表：OPEN表和CLOSE表，并将起始点S加入OPEN表。
2. 选出OPEN表中总代价f最小的节点作为当前扩展点n。
3. 如果当前扩展点n是目标点T，则根据父节点指针回溯路径，成功得到规划航迹，退出；否则，跳转步骤（4）
4. 对当前扩展点n进行扩展搜索，生成待扩展点集M。此时，当前点n为点集M中所有待扩展点的父节点。把当前扩展点n从OPEN表中移除，加入到CLOSE表中。
5. 将待扩展点集M中所有节点都添加进OPEN表中，按照f递增的顺序对OPEN表中的节点进行排序
6. 如果OPEN表为空，则表示规划失败，退出；否则，跳转步骤（2）

► A*算法的最优性分析

- 1) $h(n)$ 设为0时, A*算法将退化成Dijkstra算法, 这可以保证找到最优路径, 但算法所扩展的点数量将会急剧增加;
- 2) 如果 $h(n)$ 的值总是小于或等于当前点到目标点的实际代价, 那么A*算法能够保证找到一条最优路径。
- 3) 如果 $h(n)$ 的值能够保证总是等于从当前节点到目标点的实际代价, 那么A*算法将只会扩展最优路径上的点, 而不会扩展其他节点, 这将使得算法的规划速度非常快。
- 4) 如果 $h(n)$ 的值有时比从当前点到目标点的实际代价值高, 那么A*算法不能保证找到最优路径, 但是其搜索速度将会提高;
- 5) 如果启发函数 $h(n)$ 远远大于实际代价, 那么A*算法将演变为BFS算法。

利用A*搜索进行航迹规划


- ▶ 最小航迹段长度、最大拐弯角和最大爬升/下滑角



假定给定了起始位置，目标位置，一条从起始位置到当前节点 x 的航迹，最小航迹段长度(L)、最大拐弯角(ϕ)和最大爬升/下滑角(θ)。那么从当前位置在最大拐弯角、最大爬升/下滑角和最小航迹段长度之内能够到达的就只有有限数量的位置单元。这些单元被限制在一个由四棱锥所和球面所包围的区域内。四棱锥在顶点 x 处纵向的张角等于 2θ ，在水平方向的张角等于 2ϕ ，球面半径等于 L 。

利用A*搜索进行航迹规划

► 航迹距离约束



一个给定当前节点 x ，只有当满足 $D(x) + SL(x) \leq d_{\max}$ 时才把 x 加入到可能的路径节点。这里 $D(x)$ 是从起始位置到 x 经过的真实距离， $SL(x)$ 是从 x 到目标的直线距离。

利用A*搜索进行航迹规划



► 飞行高度限制





搜索过程中对每一个给定的节点 x ，只有当它与当前节点之间的路径上的每一点的离地高度都大于或等于给定的最小值 $H_{\min}$

时，才把它作为可能的航迹点。只要有一点不满足该条件，就认为 x 是无效航迹点。

规划结果



规划结果



进化类算法

- ② 进化计算 (Evolutionary Computation, EC) 是一类基于生物进化论和遗传学等理论的求解优化问题的随机算法。
- ② 进化算法是一种基于种群的优化方法，在进化的开始，种群被初始化，然后通过事先设置的一系列算子来控制个体的进化，适应度高的个体进入下一代的概率也高。


(2) 进化算法分类





- ▶ 遗传算法
- ▶ 粒子群优化算法
- ▶ 蚁群算法
- ▶ 差分进化算法
- ▶ 鱼群算法
- ▶ 蜂群算法
- ▶ DNA算法
- ▶ 人工免疫算法
- ▶ 分布式估计算法

A、遗传算法

- ▶ 遗传算法是基于达尔文的进化论和孟德尔的遗传学提出的，它是模拟生物在自然环境中的遗传和进化过程形成的一种全局的随机搜索和优化算法。Michalewicz在著作中将遗传算法归纳为以下几个基本组成部分：问题的解的遗传表示、创建初始种群的方法、判定个体适应值优劣的评价函数、由旧的种群产生新一代种群的遗传算子、遗传算法的参数。

遗传算法的基本流程图





(a) 第0代,
航迹初始化。
(b) 第20代,
(c) 第60代,
(d) 第120
代的最优航
迹。

B、群体智能算法



群智能算法的特点

- ✓ 群智能方法易于实现，算法中仅涉及各种基本的数学操作，其数据处理过程对CPU和内存的要求也不高
- ✓ 只需目标函数的输出值，而无需其梯度信息
- ✓ 已完成的群智能理论和应用方法研究证明群智能方法是一种能够有效解决大多数全局优化问题的新方法
- ✓ 群智能潜在的并行性和分布式特点为处理大量的以数据库形式存在的数据提供了技术保证
- ✓ 无论是从理论研究还是应用研究的角度分析，群智能理论及其应用研究都是具有重要学术意义和现实价值的


- ▶ 群体智能算法的研究开始于上世纪90年代初，其基本思想是模拟自然界生物群体行为。
- ▶ 典型的方法有M. Dorigo提出的蚁群算法（蚂蚁算法）和J. Kennedy与R. Eberthart提出的粒子群算法（微粒群算法）。

蚁群算法

- ▶ 20世纪90年代意大利学者M. Dorigo, V. Maniezzo, A. Colorni等从生物进化的机制中受到启发，通过模拟自然界蚂蚁搜索路径的行为，提出一种新型的模拟进化算法——蚁群算法，是群智能理论研究领域的一种主要算法。用该方法求解TSP问题、分配问题、job-shop调度问题，取得了较好的试验结果。虽然研究时间不长，但是现在的研究显示出，蚁群算法在求解复杂优化问题（特别是离散优化问题）方面有一定优势，表明它是一种有发展前景的算法。



Dorigo



首次正式提出蚁群算法的文章：M. Dorigo, V. Maniezzo, and A. Coloni, "Ant system: optimization by a colony of cooperating agents," *IEEE Transactions on Systems, Man, and Cybernetics, Part B: Cybernetics*, vol. 26, no. 1, pp. 29-41, 1996.

蚁群算法的优点


群智能依靠的是概率搜索算法。虽然概率搜索算法通常要采用较多的评价函数，但是与梯度方法及传统的演化算法相比，其优点还是显著的，主要表现在以下几个方面：

- 无集中控制约束，不会因个别个体的故障影响整个问题的求解，确保了系统具备更强的鲁棒性
- 以非直接的信息交流方式确保了系统的扩展性
- 并行分布式算法模型，可充分利用多处理器
- 对问题定义的连续性无特殊要求
- 算法实现简单

粒子群优化 (PARTICLE SWARM OPTIMIZATION) 方法



Russ Eberhart



James Kennedy

PSO的提出者

PSO的社会学背景



- ▶ 由Eberhart和Kennedy于1995年提出的粒子群优化算法(Particle Swarm Optimization, 简称PSO)是一种全局优化进化算法, 其源于对鸟群觅食行为的模拟。
- ▶ PSO作为新兴的群智能优化方法, 以其形式简单和性能高效的特点, 赢得了研究者们的关注, 并已经在人工神经网络、数据挖掘、生物工程、模糊系统控制等众多涉及参数优化的问题中得到了广泛的应用, 其已经成为现代工程技术中一种重要的并流行的优化方法。

PSO算法原理

设 $X_i = (x_{i1}, x_{i2}, x_{i3}, \dots, x_{iD})$ 为粒子 i 在 D 维空间中的位置矢量,

$V_i = (v_{i1}, v_{i2}, v_{i3}, \dots, v_{iD})$ 为粒子 i 在 D 维空间中的速度矢量,

$pbest_i = (p_{i1}, p_{i2}, p_{i3}, \dots, p_{iD})$ 为粒子 i 目前能搜索到的局部最优位置,

$gbest_i = (g_{i1}, g_{i2}, g_{i3}, \dots, g_{iD})$ 为整个粒子种群目前搜寻到的全局最优位置

粒子的速度和位置更新方程


$$V_{id}^{t+1} = w * V_{id}^t + c_1 * rand() * (pbest_{id} - X_i^t) + c_2 * rand() * (gbest_d - X_{id}^t)$$

$$X_{id}^{t+1} = X_{id}^t + V_{id}^{t+1}$$

PSO与EA的异同


- ▶ 相同点：粒子群优化算法(PSO)同样也是基于种群的智能优化算法；
- ▶ 不同点：
 - ▶ 1) 没有“适者生存”的机制，所有的个体(粒子)在迭代的过程中始终作为种群的成员保留；
 - ▶ 2) 没有进化算子(如交叉算子，变异算子等)的作用，每个粒子通过跟踪自身迄今搜索到的最优位置(个体最优粒子，也叫个体极值) $pbest$ 和整个种群迄今搜索到的最优位置(全局最优粒子，也叫全局极值) $gbest$ 来控制粒子的运动。

多种群协进化蚁群规划算法



协进化多子群蚁群结构图


多子群协同规划算法流程图



航迹输出与演示验证

t	弹目距离	理论经度	理论纬度	理论高度	左上经度	左上纬度	左上高度	左下经度	左下纬度	左下高度	右上经度	右上纬度	右上高度
0.500	999999.00	107.094565	31.013764	0.000	107.099805	31.013765	1093.601	107.099805	31.013765	893.601	107.089328	31.013765	89.999
1.000	999999.00	107.094565	31.013764	1004.000	107.099805	31.013765	1104.103	107.099805	31.013765	904.103	107.089328	31.013765	89.987
1.500	999999.00	107.094565	31.013764	1018.764	107.099805	31.013769	1118.897	107.099805	31.013769	918.897	107.089328	31.013762	86.114
2.000	999999.00	107.094564	31.013763	1036.958	107.099805	31.013769	1137.117	107.099805	31.013769	937.117	107.089328	31.013755	66.983
2.500	999999.00	107.094557	31.013741	1057.966	107.089519	31.014967	1158.141	107.089519	31.014967	958.141	107.099601	31.012515	40.732
3.000	999999.00	107.094536	31.013679	1080.030	107.089512	31.014940	1180.205	107.089512	31.014940	980.205	107.099566	31.012420	21.857
3.500	999999.00	107.094498	31.013564	1101.369	107.089485	31.014865	1201.534	107.089485	31.014865	1001.534	107.099512	31.012259	14.789
4.000	999999.00	107.094439	31.013393	1121.417	107.089430	31.014708	1221.572	107.089430	31.014708	1021.572	107.099443	31.012078	13.235
4.500	999999.00	107.094358	31.013163	1140.233	107.089342	31.014445	1240.379	107.089342	31.014445	1040.379	107.099382	31.011883	13.219
5.000	999999.00	107.094257	31.012871	1158.006	107.089226	31.014107	1258.145	107.089226	31.014107	1058.145	107.099293	31.011634	13.414
5.500	999999.00	107.094134	31.012516	1174.904	107.089096	31.013724	1275.036	107.089096	31.013724	1075.036	107.099177	31.011306	13.778
6.000	999999.00	107.093991	31.012096	1191.067	107.088945	31.013294	1291.194	107.088945	31.013294	1091.194	107.099040	31.010896	14.179
6.500	999999.00	107.093828	31.011611	1206.622	107.088782	31.012809	1306.744	107.088782	31.012809	1106.744	107.098877	31.010411	14.243
7.000	999999.00	107.093643	31.011061	1221.631	107.088597	31.012266	1321.749	107.088597	31.012266	1121.749	107.098692	31.009855	14.237
7.500	999999.00	107.093438	31.010446	1236.143	107.088399	31.011668	1336.257	107.088399	31.011668	1136.257	107.098480	31.009223	14.263
8.000	999999.00	107.093212	31.009766	1250.218	107.088180	31.011006	1350.329	107.088180	31.011006	1150.329	107.098248	31.008526	14.242
8.500	999999.00	107.092965	31.009023	1263.913	107.087928	31.010271	1364.021	107.087928	31.010271	1164.021	107.097995	31.007778	14.140
9.000	999999.00	107.092696	31.008218	1277.274	107.087661	31.009462	1377.380	107.087661	31.009462	1177.380	107.097729	31.006976	13.985
9.500	999999.00	107.092408	31.007353	1290.339	107.087375	31.008591	1390.443	107.087375	31.008591	1190.443	107.097442	31.006112	13.847
10.000	999999.00	107.092101	31.006430	1303.158	107.087067	31.007666	1403.259	107.087067	31.007666	1203.259	107.097135	31.005193	13.753
10.500	999999.00	107.091776	31.005452	1315.763	107.086739	31.006689	1415.863	107.086739	31.006689	1215.863	107.096807	31.004216	13.682
11.000	999999.00	107.091439	31.004441	1327.664	107.086405	31.005678	1427.753	107.086405	31.005678	1227.753	107.096472	31.003206	13.633

软件界面



规划预处理参数设定界面

匹配区专题图生成

参数信息

高程初选

初选区域大小

2000.00

(单位: m)

高差阈值

0.00

(单位: m)

标准差阈值

0.00

边缘增强

扩展边缘宽度

30

(单位: 像素)

图像均衡

无参数

标准差图 | 独立像元数 | 相关峰之比

实时图大小

360

(单位: m)

步长比率

0.25

相关区大小

2000

(单位: m)

标准差图阈值

20.00

独立像元数阈值

80.00

相关峰阈值

1.30

景象匹配

高度

10

20

30

(单位: km)

散布

25

30

35

40

(单位: m)

方向个数

8

采样间隔

0.10

(单位: 秒)

飞行速度

3400.00

(单位: m/s)

最大侧视角

15.00

(单位: 度)

最小侧视角

10.00

(单位: 度)

滤波频率

0.00

景象匹配区图

计算

暂停

高程初选

100%

边缘处理

100%

图像均衡化

100%

标准差图

独立像元数

100%

相关峰之比

匹配区图

100%

雷达测高匹配区图

计算

暂停

地形分类

100%


修正带均值图

100%


雷达测高匹配

100%


稀疏A*算法规划界面




稀疏A*规划




协同规划




协同规划




(3) 深度强化学习方法




基于大模型推理引导的分层规划




UUV编队航行



编队快速重组



LLM引导的UUV编队任务规划结果



基于深度强化学习的航迹规划策略自学习方法


➤ 搜索算法设计

从起始点开始，由当前导航点一步步搜索下一个导航点直至终点




➤ 航迹规划策略

依据当前节点处飞行器的状态选取下一个节点的决策方法




基于深度强化学习的航迹规划策略自学习方法

状态设计——利用一组大小为 $N \times N$ 的二值特征图层表示



匹配导航点处的飞行器状态图像表示(13张)



转弯导航点处的飞行器状态图像表示(16张)

状态与动作

回报函数

策略表达形式

策略引导智能体

策略学习总流程

基于深度强化学习的航迹规划策略自学习方法

回报函数设计——采用回报成型技术

在航迹规划策略确定下一匹配导航点后，该动作的奖惩值为：

$$r = r_{\text{len}} + r_{\text{safe}} + r_{\text{angle}} + r_{\text{inspiration}} + r_{\text{arrive}}$$

- r_{len} 为航迹长度惩罚值
- r_{safe} 为安全性能惩罚值（禁飞和威胁区）
- r_{angle} 为飞行器拐弯机动耗能惩罚值
- $r_{\text{inspiration}}$ 为启发信息奖惩值
- r_{arrive} 为规划成功奖赏值

状态与动作

回报函数

策略表达形式


策略引导智能体

策略学习总流程

基于深度强化学习的航迹规划策略自学习方法

航迹规划策略网络设计

- 基于Actor-Critic方法，利用深度卷积神经网络逼近价值函数和策略。
- 网络输入为飞行器所处的状态，输出概率分布 p 和数值 v ， $(p, v) = f_{\theta}(s)$ 。
- 设计了转弯点规划策略网络和匹配点规划策略网络，它们的网络架构一样。



状态与动作

回报函数


策略表达形式

策略引导智能体

策略学习总流程

基于深度强化学习的航迹规划策略自学习方法

基于MCTS利用当前的规划策略网络引导无人飞行器



状态与动作

回报函数

策略表达形式

策略引导智能体

策略学习总流程

基于深度强化学习的航迹规划策略自学习方法

规划策略网络分两个步骤进行迭代学习

(1) 飞行器探索环境生成样本数据

对于每一个状态 s_t ，飞行器依据MCTS利用当前的规划策略网络得到的下一节点的选择概率 π_t 采取动作 a_t ，然后转换到状态 s_{t+1} 。回报函数测量该动作的奖惩值 r_{t+1} 并反馈给飞行器。重复以上过程，直至 T 时刻达到终止状态（规划成功或失败）。统计状态 s_t 的价值 $R_t = \sum_{i=t+1}^T r_i$ 。依据状态 s_t 的导航点类型按照 (s_t, π_t, R_t) 的形式将样本数据分别存入规划转弯点和规划匹配点的记忆库。

(2) 规划策略网络学习样本数据

规划策略网络从对应的记忆库中随机批量采样样本 (s_t, π_t, R_t) 进行学习。神经网络的损失函数定义为： $loss = (R - v)^2 - \pi^T \ln p + c ||\theta||^2$

为了确保规划策略网络更新过程平稳进行，通过计算规划策略网络更新前后概率分布的KL散度来控制学习率。

状态与动作

回报函数

策略表达形式

策略引导智能体

策略学习总流程

航迹规划策略学习效果评估与分析

评估规划策略网络效果：基于MCTS利用当前的规划策略网络引导无人飞行器规划得到的航迹的总奖惩值 $R=\sum_{i=0}^T r_i$ 来评估。【注：选择 π_t 中最大概率的动作】

实验设置

- 本论文方法是否一定能完成规划任务？

实验1 基于随机初始化参数的规划策略网络规划得到的航迹的性能进行分析

- 本论文方法是否有规划策略网络学习的能力，学习到的规划策略网络是否具有应用于未知的飞行任务和环境的泛化能力？

实验2 评估规划策略网络在未知飞行环境的泛化能力



实验3 评估规划策略网络在新的飞行任务中的泛化能力

- 本论文方法相对其他方法是否具备优势？

实验4 与A*航迹规划方法的对比实验

航迹规划策略学习效果评估与分析

实验1 基于随机初始化参数的规划策略网络规划得到的航迹的性能进行分析





结论: 在仿真次数足够的情况下, 本论文方法能完成规划任务, 即规划出满足约束条件, 安全成功到达目的地的航迹。

航迹规划策略学习效果评估与分析

实验2 评估规划策略网络在未知飞行环境的泛化能力

在10个规划任务相同，但飞行环境不同的情况下进行规划策略网络迭代学习，然后在测试规划环境图上评估不同阶段学习得到的规划策略网络



结论：


- 具备学习能力，能够以更少的仿真次数成功规划航迹，提高了规划效率。
- 规划策略网络从历史经验中学习到了有价值的策略，在未知的飞行环境中具有泛化能力。

航迹规划策略学习效果评估与分析

实验3 评估规划策略网络在新的飞行任务中的泛化能力

在28个飞行环境相同，不同的飞行任务的规划环境图上进行规划策略网络迭代学习，在测试飞行任务的规划环境图上评估不同阶段学习得到的规划策略网络


飞行任务的编号	起始点高斯坐标	目标点高斯坐标	起始点进入方向
1	F	A	-135
2	F	A	-110
3	F	B	-160
4	F	B	-135
5	F	B	-110
6	F	C	-160
7	F	C	-135
8	F	C	-110
9	F	D	-160
10	F	D	-135
11	F	D	-110
12	F	E	-160
13	F	E	-135
14	F	E	-110




结论：规划策略网络对新的飞行任务具有一定的适应性。

航迹规划策略学习效果评估与分析


实验4 与A*航迹规划方法的对比实验



规划环境图



A*航迹规划方法规划结果
(回退230次, 总耗时14.55min)



学习120次网络、仿真120次
(耗时4.3min)

结论: 在本实验的规划环境中, 本文所提方法相比于传统A*航迹规划方法来说, 具有学习的能力, 并且具有前瞻性预判性的优势, 虽然得到的航迹略差, 但是规划航迹耗时更少。